İSTANBUL TİCARET ÜNİVERSİTESİ

# Yapay Zekâ ve Büyük Veri ile Finans Makinaları Nasıl Akıllandırırız?

*Danışman: Doç. Dr. Agah Tuğrul KORUCU*

*Hazırlayan: Onur Muhammet AKÇAY*

# İçindekiler

İSTANBUL TİCARET ÜNİVERSİTESİ


1 · Makineleri Nasıl Akıllandırırız?
2 · Sunumun Amacı
3 · Yapay Zekâ Nedir?
4 · Yapay Zekâ Tarihsel Evrim
5 · AI – ML – DL İlişkisi
6 · Öğrenme Tanımı (Tom Mitchell)
7 · Matematiksel Model
8 · Öğrenme Paradigmaları
9 · Denetimli Öğrenme
10 · Denetimsiz Öğrenme
11 · Pekiştirmeli Öğrenme
12 · Temel Algoritmalar
13 · Sinir Ağları
14 · Derin Öğrenme Neden Güçlü?
15 · Eğitim Süreci (Pipeline)
16 · Veri Kalitesi
17 · Eğitim ve Test Ayrımı
18 · Overfitting vs Underfitting
19 · Genelleme Nedir?
20 · Bilgi Temsili
21 · Model Nasıl "Anlar"?
22 · Güncel Araştırma Alanları
23 · Veri ve Etik
24 · Kritik Tartışma
25 · Özet
26 · Kaynakça

# Makinaları nasıl akıllandırırız?

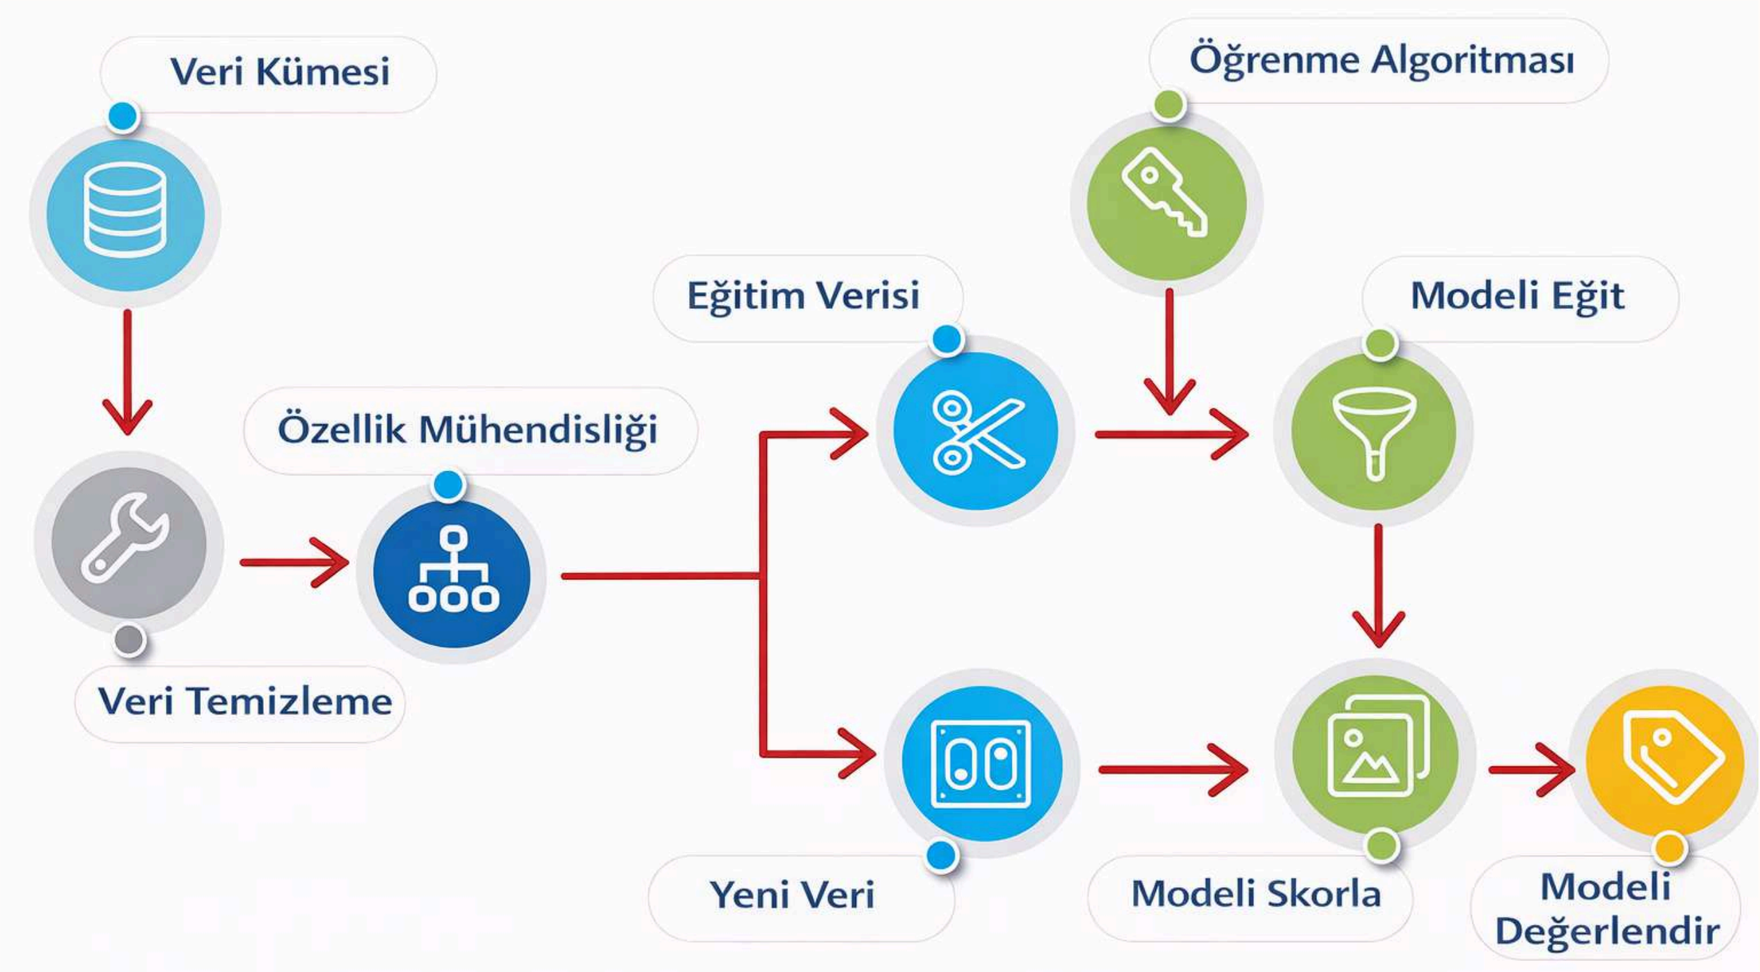


**Bu sunumda, makinelerin veri temelli öğrenme süreçleri ve matematiksel modeller aracılığıyla karar verme yetkinliklerini nasıl geliştirdiği incelenecektir.**

# Sunumun Amacı

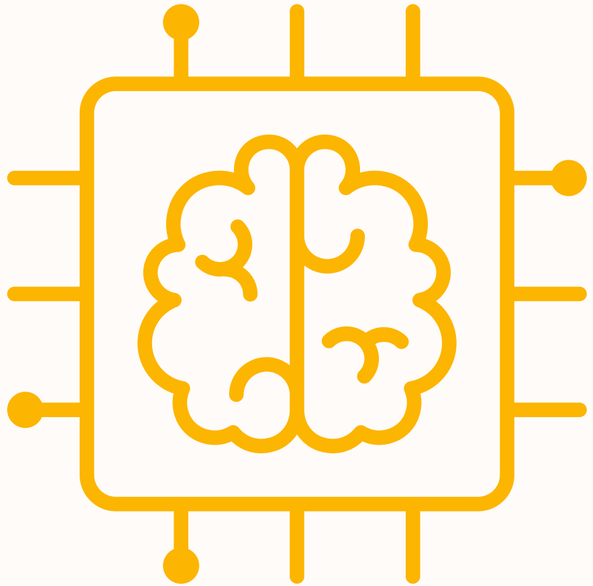

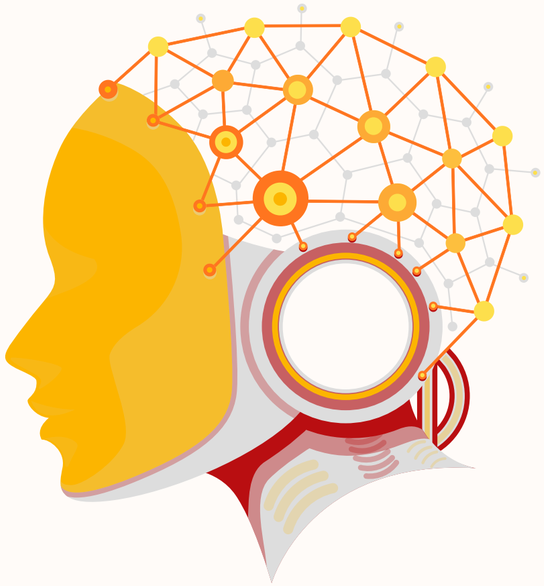

**Bu sunum sonunda:**

- **Yapay zekânın kuramsal altyapısını tanımlayabileceksiniz.**
- **Makine öğrenmesi modellerinin matematiksel dayanaklarını yorumlayabileceksiniz.**
- **Veri–model etkileşimini sistematik biçimde analiz edebileceksiniz.**
- **Bilgi temsili kavramını hesaplamalı perspektiften değerlendirebileceksiniz.**

# Yapay Zekâ Nedir?

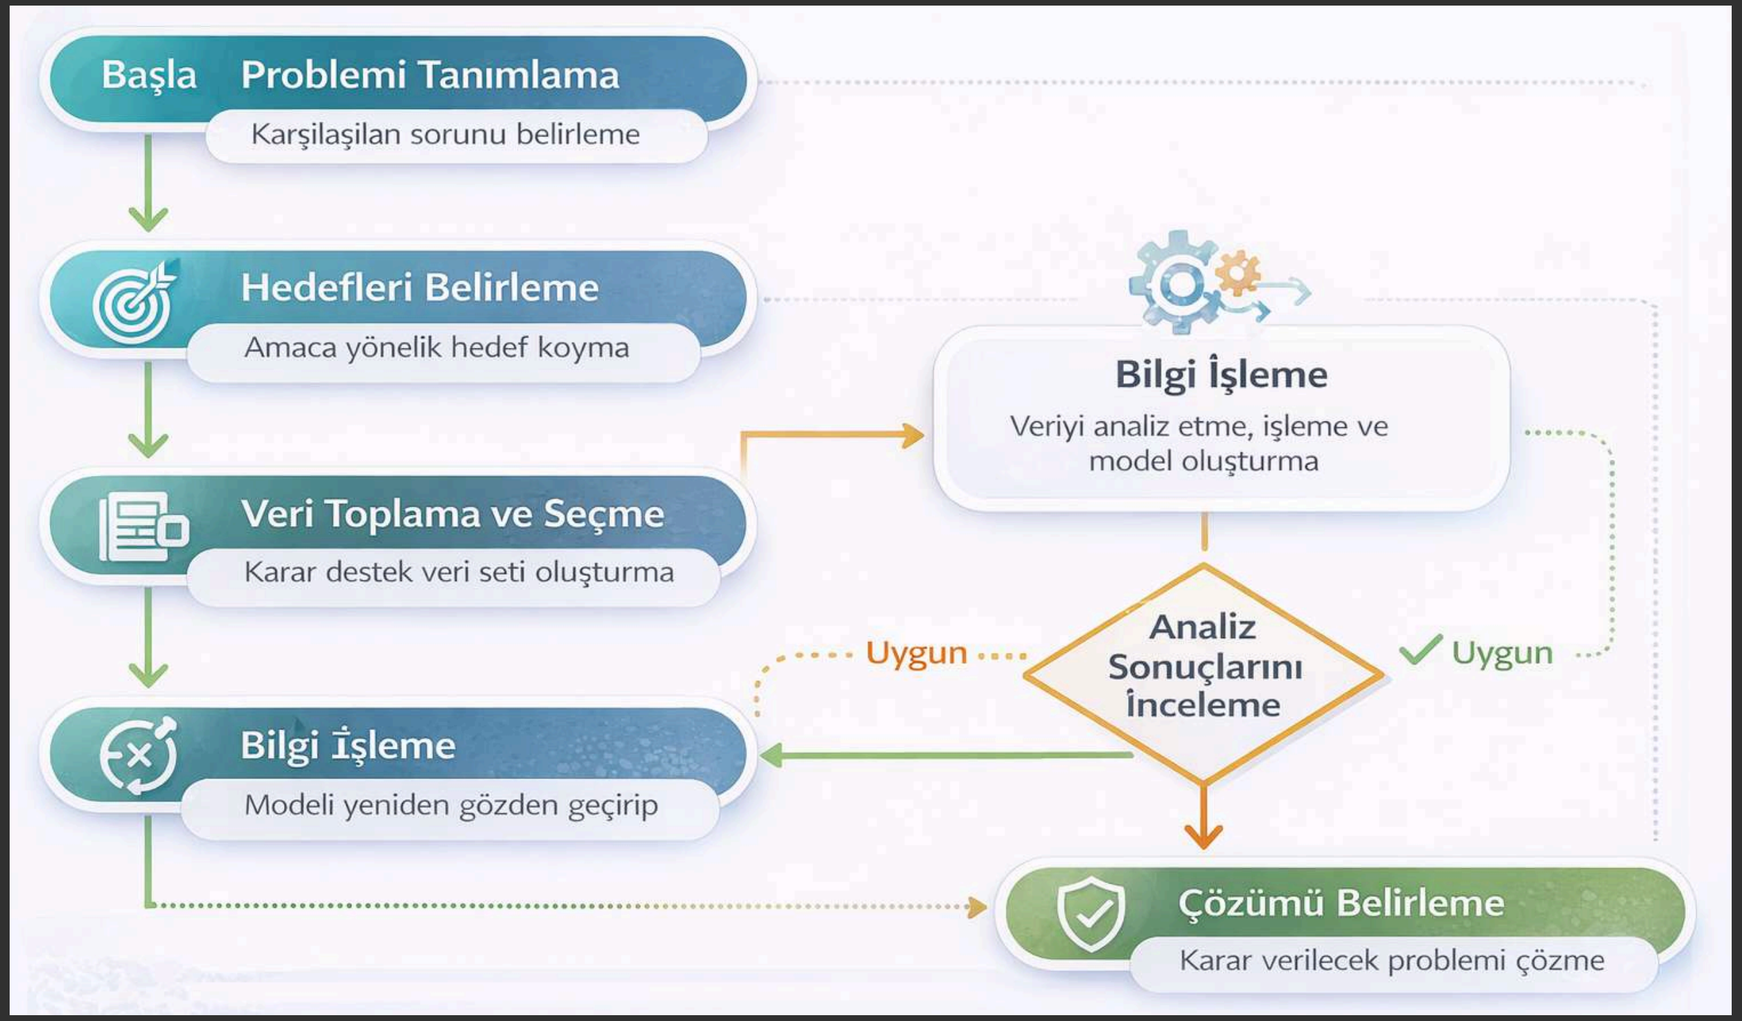


**Yapay zekâ, insan bilişsel süreçlerinin matematiksel modeller ve algoritmalar aracılığıyla bilgisayar sistemlerinde temsil edilmesi ve simüle edilmesidir.**

# Yapay Zekâ Tarihsel Evrim

| Dönem | *Temel Yaklaşım* | **Özellik** |
|---|---|---|
| 1950s | *Sembolik AI* | **Mantıksal kurallar** |
| 1970s | *Uzman Sistemler* | **Bilgi tabanı** |
| 1990s | *Makine Öğrenimi* | **İstatistiksel modeller** |
| 2010+ | *Derin Öğrenme* | **Büyük veri + GPU** |

**Yapay zekâ fikri, makinelerin yalnızca hesaplama yapan araçlar değil, düşünebilen sistemler hâline gelebileceği sorusuyla ortaya çıktı. Bu fikir 1950'li yıllarda bilimsel bir araştırma alanına dönüştü.**

# Yapay Zekâ Tarihsel Evrim

Günümüzde Yapay Zeka
(AI vs İnsan)

# AI – ML – DL İlişkisi

- **Artificial Intelligence (AI)**

- İnsan benzeri düşünme ve karar verme süreçlerinin bilgisayarlarda modellenmesidir.
- En geniş alandır; kural tabanlı sistemleri de kapsar.

- **Machine Learning (ML)**

- AI’nin bir alt alanıdır.
- Sistemlerin veriden öğrenmesini sağlar.

- **Deep Learning (DL)**

- ML’nin alt alanıdır.
- Çok katmanlı sinir ağlarıyla karmaşık problemleri çözer.

# AI – ML – DL İlişkisi

# AI – ML – DL İlişkisi

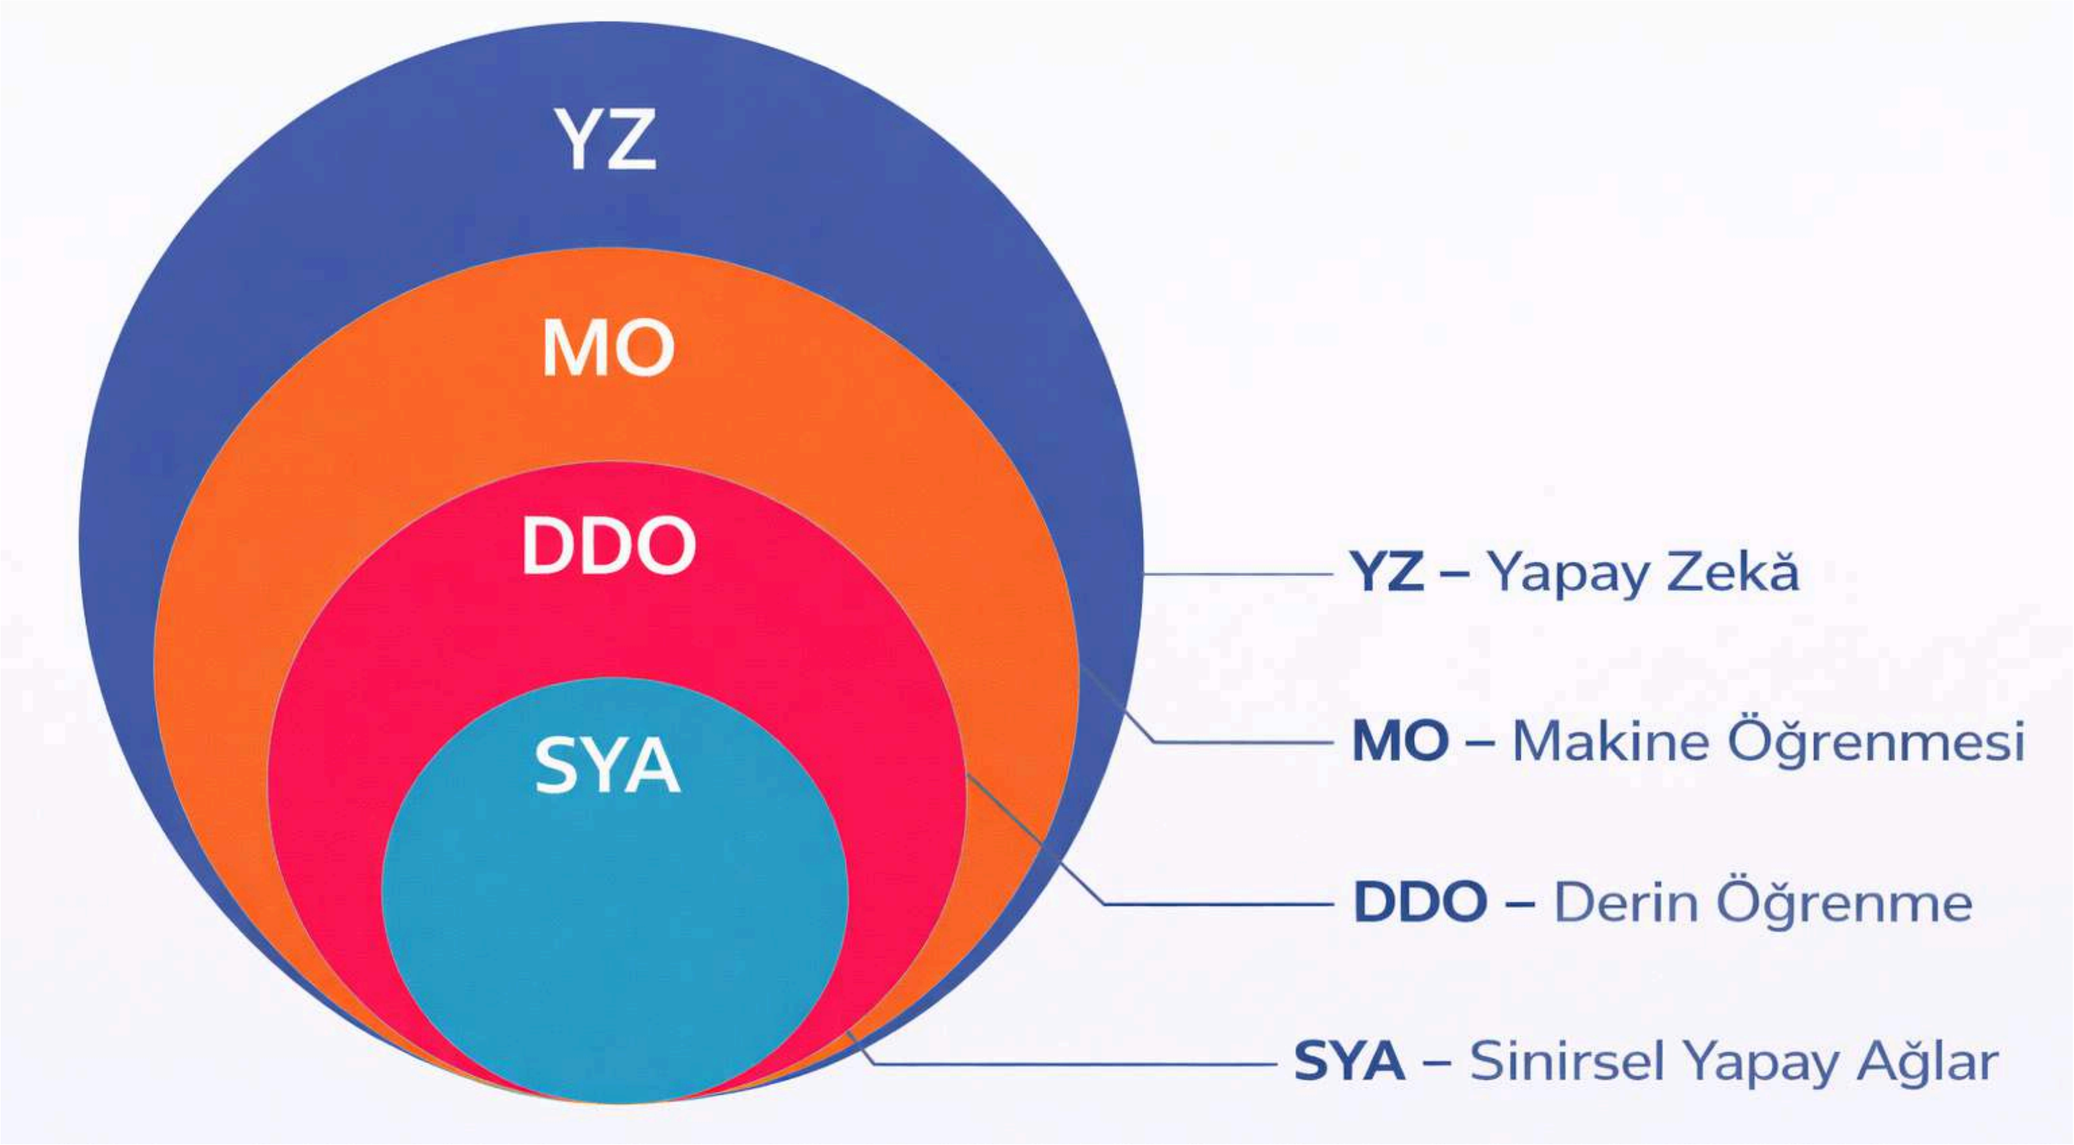

# Öğrenme Tanımı (Tom Mitchell)

## Mitchell'e göre:

**"Bir bilgisayar programı, T görev kümesi ve P performans ölçütü bağlamında, E deneyimi ile performansını artırıyorsa öğreniyor kabul edilir."**

**T (Task / Görev): Modelin yerine getirmesi beklenen problem (örneğin: e-posta sınıflandırma)**

**E (Experience / Deneyim): Modelin beslendiği veri (örneğin: geçmiş e-posta örnekleri)**

**P (Performance / Performans Ölçütü): Başarıyı ölçen kriter (örneğin: doğruluk oranı)**

# Öğrenme Tanımı (Tom Mitchell)

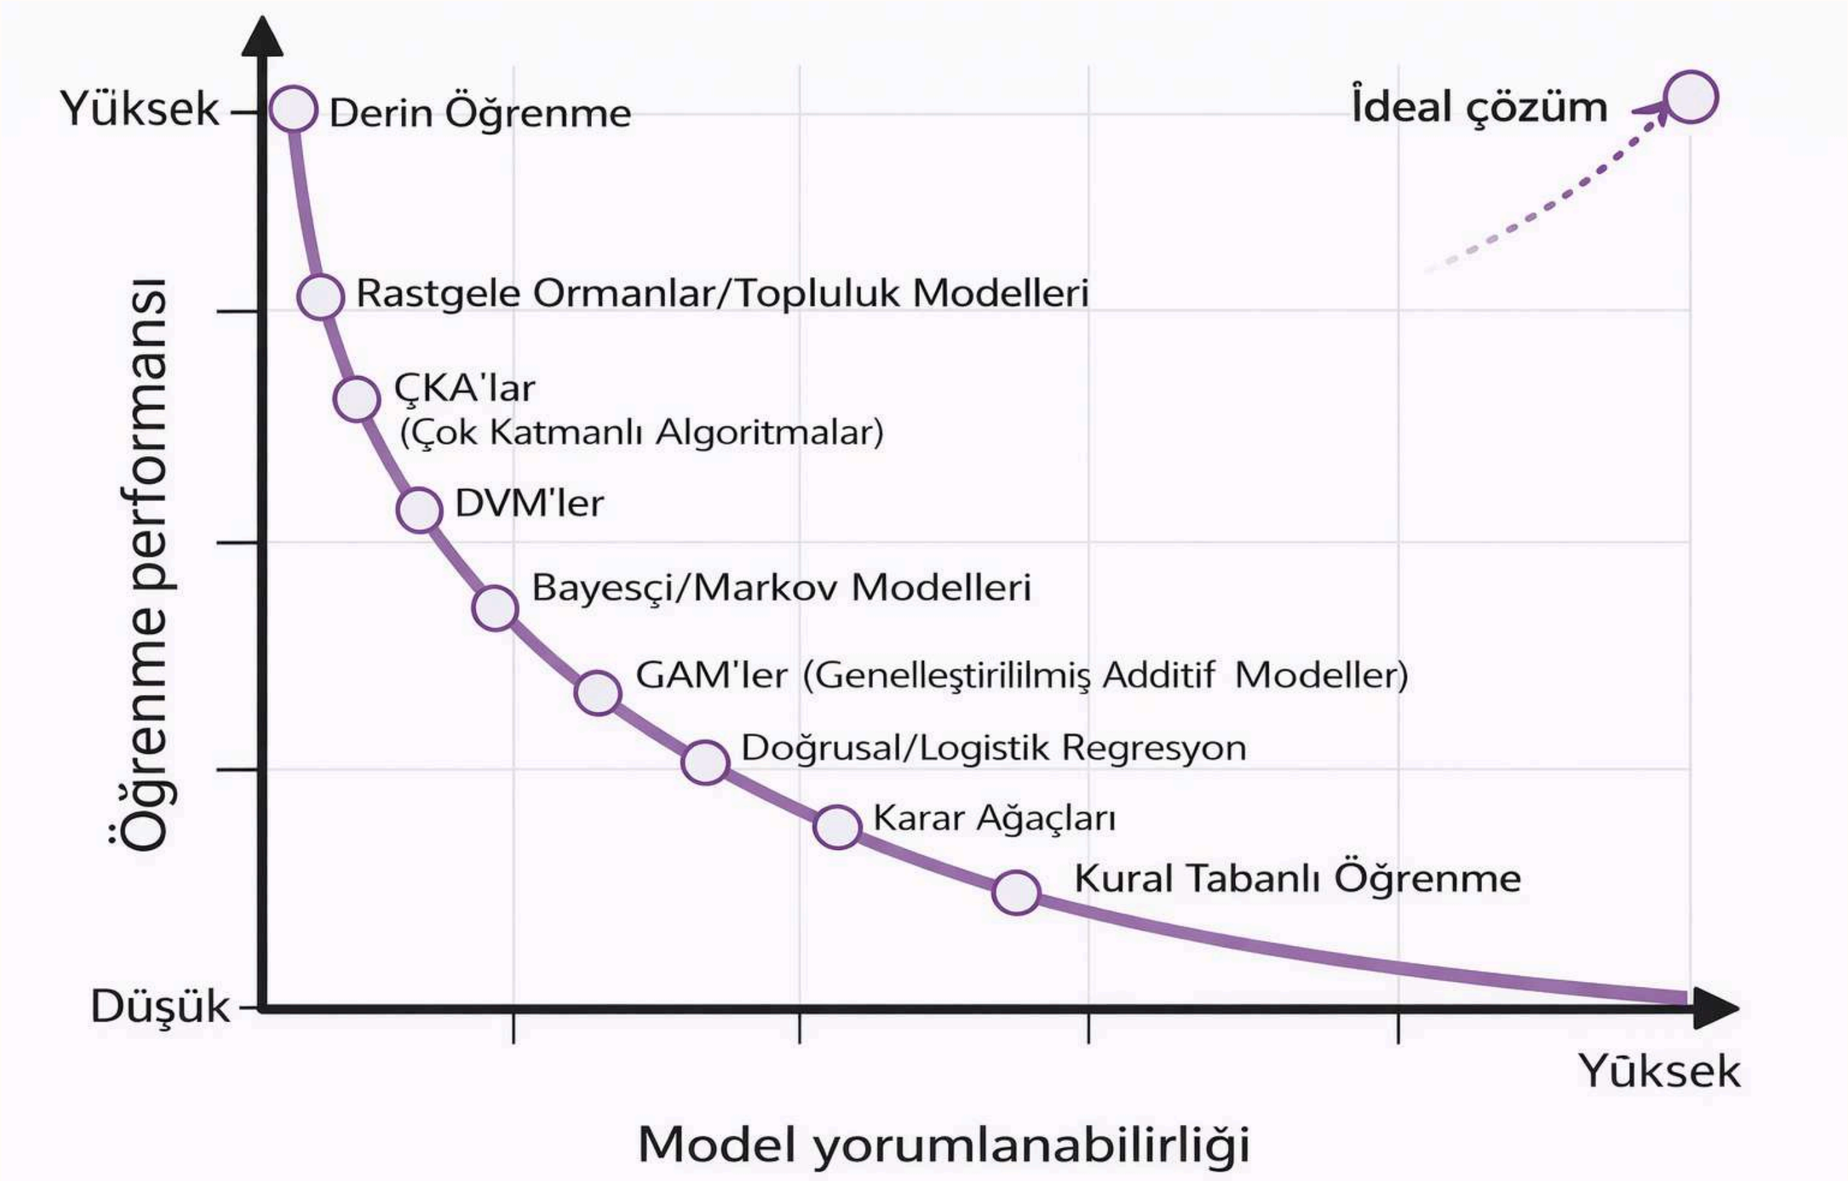

# Matematiksel Model

Makine öğrenmesinde öğrenme, veriler arasındaki ilişkiyi matematiksel bir yapı ile ifade etme sürecidir.

Elimizde girdiler (x) ve bu girdilere karşılık gelen çıktılar (y) vardır. Amaç, bu ilişkiyi temsil eden bir fonksiyon bulmaktır:

$$y \approx f(x)$$

Model başlangıçta rastgele başlar. Eğitim sürecinde tahmin ile gerçek değer arasındaki fark ölçülür ve bu hata azaltılmaya çalışılır.

Bu nedenle makine öğrenmesi, özünde veriye en iyi uyan fonksiyonu bulmaya yönelik bir optimizasyon problemidir.

# Matematiksel Model

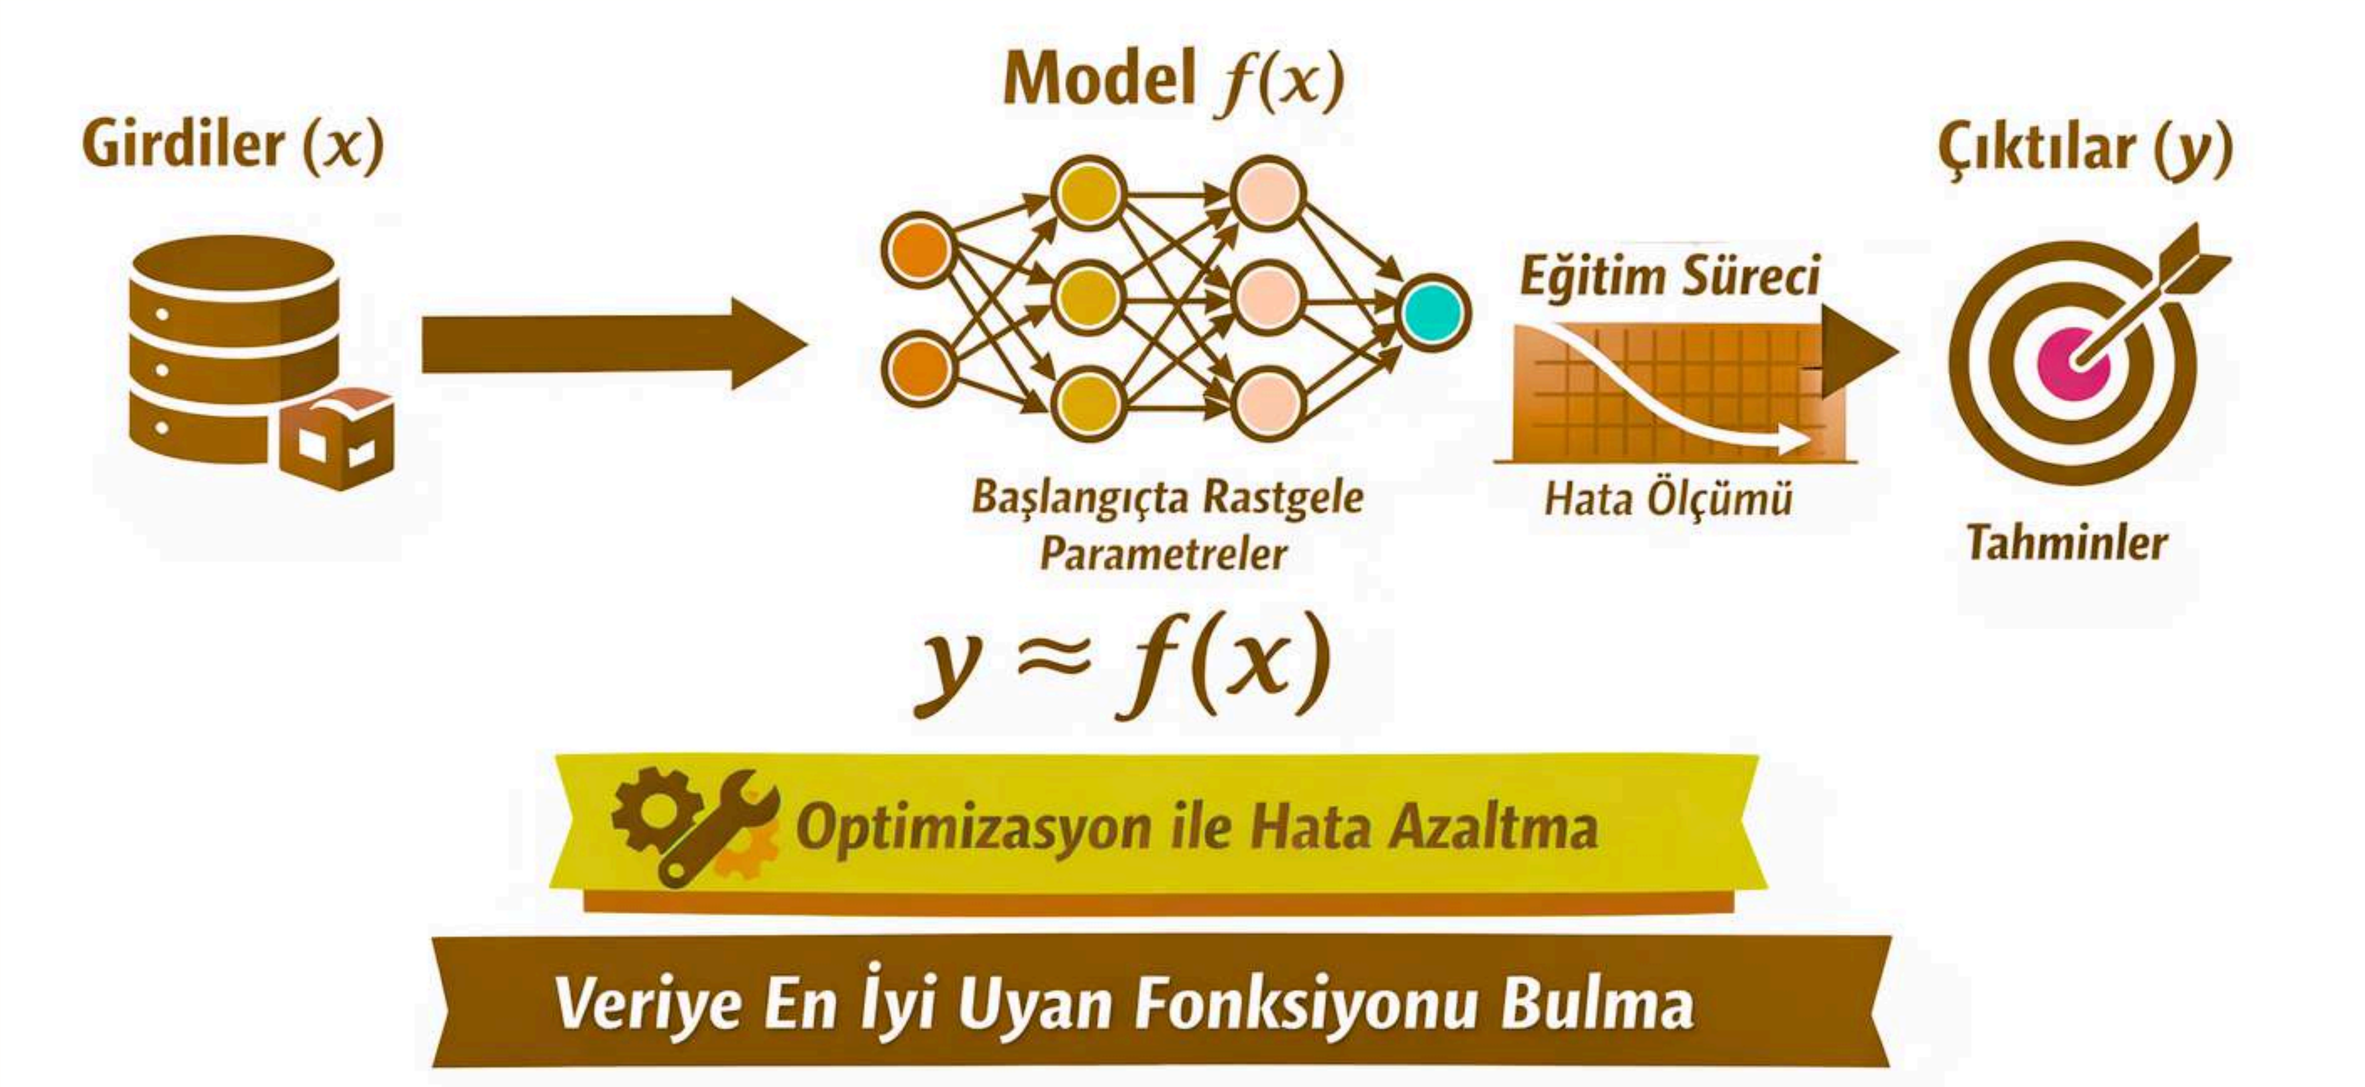

# Öğrenme Paradigmaları

- Öğrenme Paradigmaları

Makine öğrenmesinde farklı öğrenme yaklaşımları vardır. Modelin veriyi nasıl aldığı ve geri bildirimi nasıl aldığı bu farkı belirler.

- Denetimli Öğrenme:

Doğru cevapların bilindiği verilerle eğitilir, tahmin yapmayı öğrenir.

- Denetimsiz Öğrenme:

Etiket yoktur; model verideki gizli yapıları keşfeder.

- Pekiştirmeli Öğrenme:

Model, eylem yapar ve ödül/ceza alarak en iyi stratejiyi geliştirir.

Özetle, fark geri bildirimin nasıl verildiğidir.

# Öğrenme Paradigmaları

## Denetimli Öğrenme

- Etiketli veri
- Doğru çikti tahmini

- Etiketli veri
- Doğru çikti tahmini

## Denetimsiz Öğrenme

- Etiketsiz veri
- Örüntü / küme keşfi

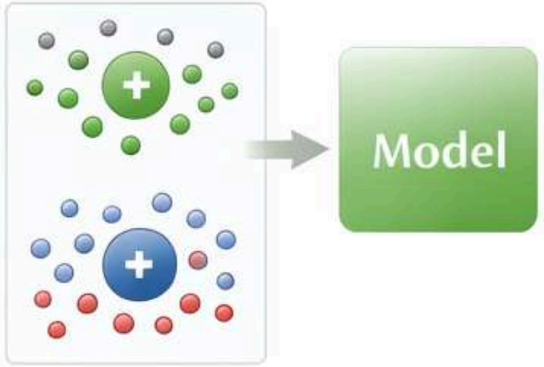


- Etiketsiz veri
- Örüntü / küme keşfi

## Pekiştirmeli Öğrenme

- Aksiyon ve ödül
- Strateji öğrenme

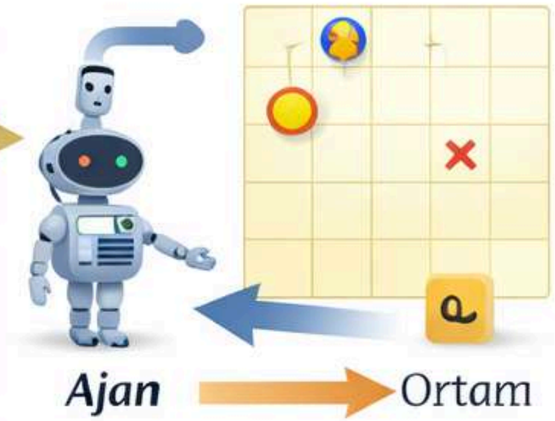


- Aksiyon ve ödül
- Strateji öğrenme

# Denetimli Öğrenme

- Denetimli Öğrenme

Denetimli öğrenmede model, doğru cevapların bilindiği verilerle eğitilir. Yani her girdinin karşılığında doğru bir çıktı vardır.

Model, kendi tahmini ile gerçek sonuç arasındaki farkı ölçer ve bu hatayı azaltarak öğrenir.

Genellikle iki tür problemde kullanılır:
- Sınıflandırma (kategori tahmini)
- Regresyon (sayısal tahmin)

Amaç, yeni gelen veriler için mümkün olan en doğru tahmini üretebilmektir.

# Denetimli Öğrenme

| Veri | Etiket |
|---|---|
| Kedi | Kedi |
| Kedi | Kedi |
| Köpek | Köpek |

Etiketli Veri

Model

Kedi Köpek

# Denetimsiz Öğrenme

- **Denetimsiz Öğrenme**

**Denetimsiz öğrenmede model, yalnızca veriyi görür; doğru cevaplar ya da etiketler verilmez. Bu nedenle sistemin görevi, verinin iç yapısını kendi başına keşfetmektir.**

**Model, benzer özelliklere sahip verileri gruplayabilir ya da gizli örüntüleri ortaya çıkarabilir. Yani burada amaç tahmin yapmaktan çok, veriyi anlamaktır.**

**En yaygın kullanım alanları:**
**- Kümeleme (benzer verileri gruplama)**
**- Boyut indirgeme (karmaşık veriyi sadeleştirme)**

**Kısaca, denetimsiz öğrenmede model yönlendirilmez; verinin iç düzenini kendi keşfeder.**

# Denetimsiz Öğrenme

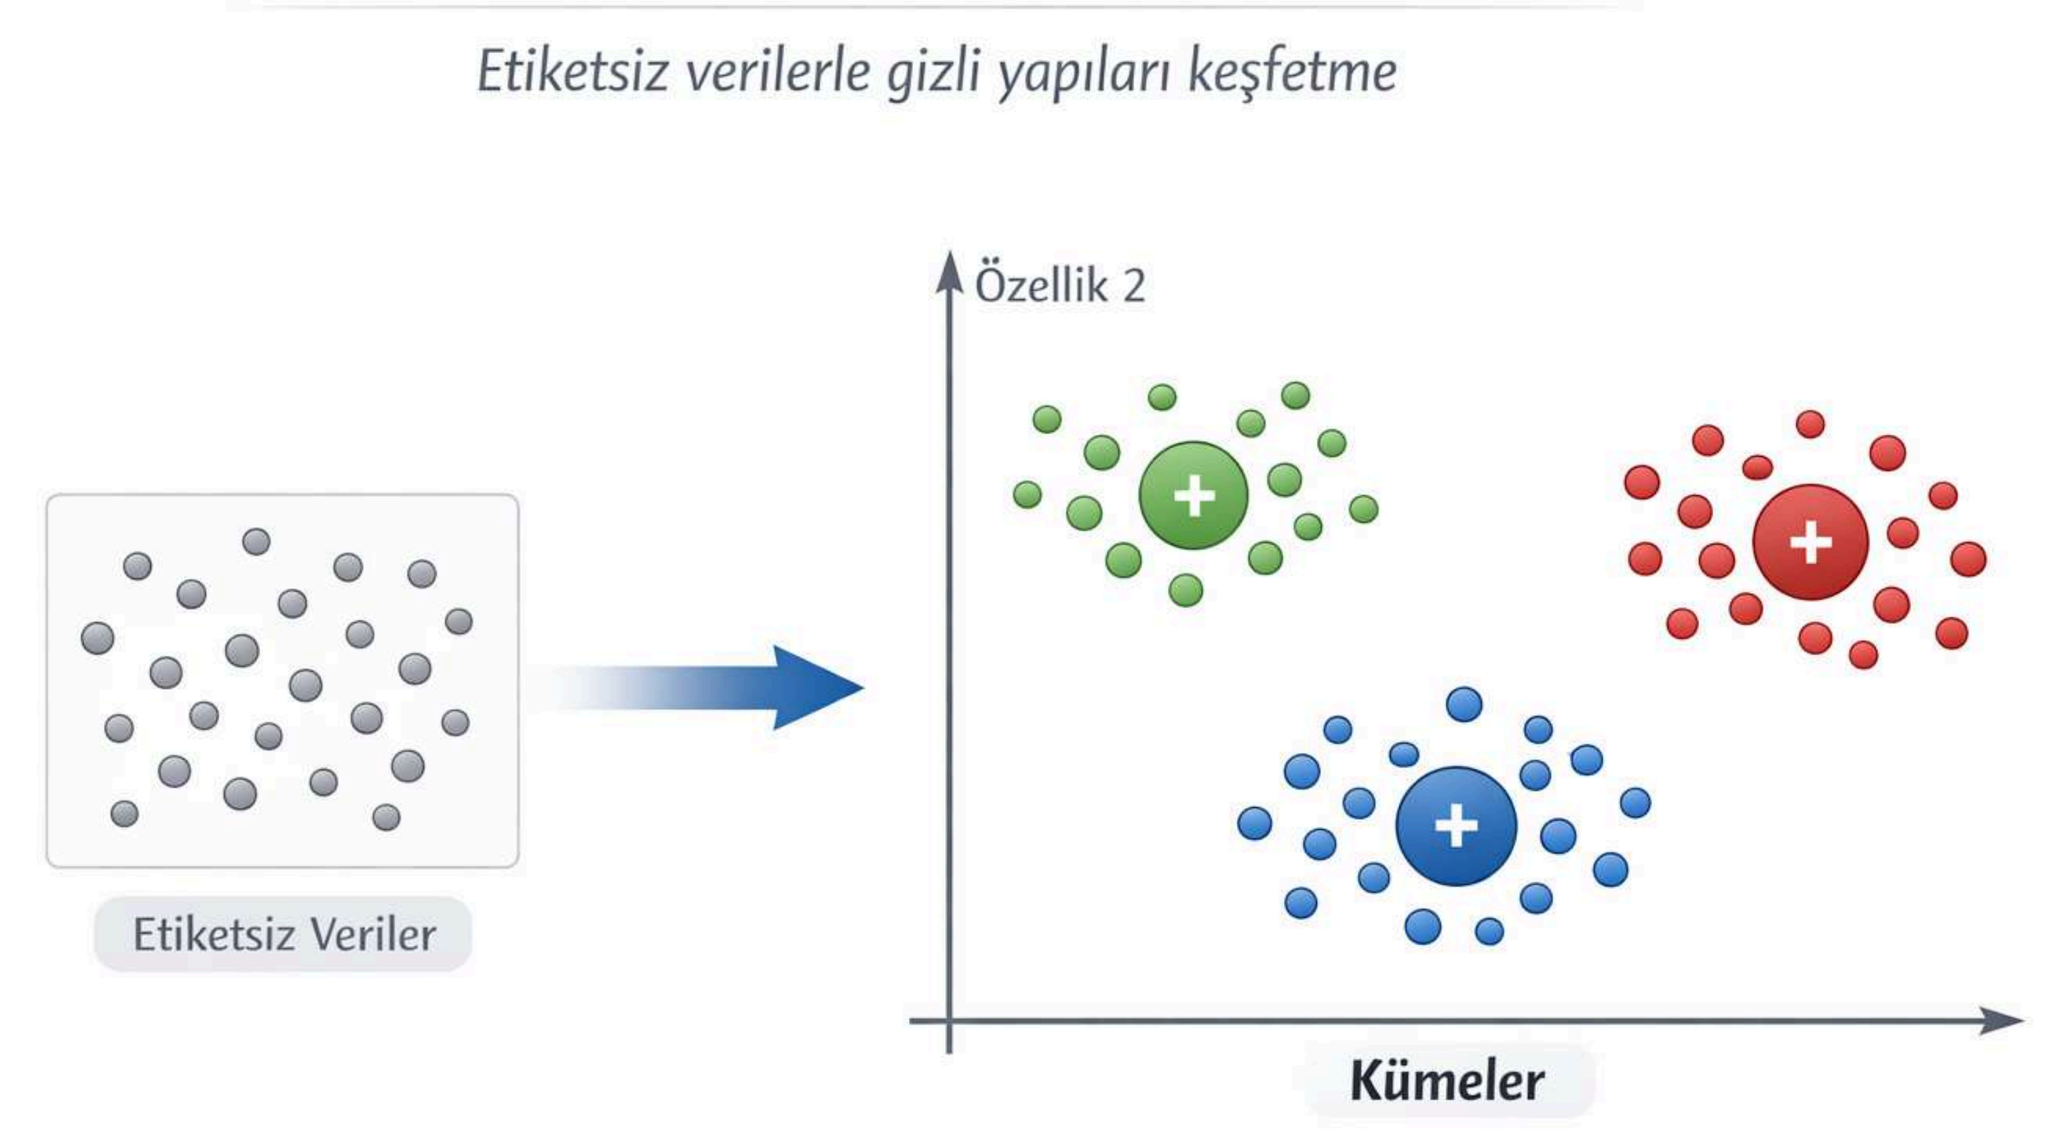

# Pekiştirmeli Öğrenme

- Pekiştirmeli Öğrenme (Reinforcement Learning)

Pekiştirmeli öğrenme, bir ajanın (agent) bir ortam ile etkileşime girerek yaptığı eylemler sonucunda aldığı ödül veya ceza geri bildirimlerine göre en iyi stratejiyi öğrenmesine dayanan bir öğrenme yaklaşımıdır.

Amaç, zaman içinde toplam ödülü maksimize eden davranış politikasını (policy) geliştirmektir.

Kısaca:
Ajan → Aksiyon alır → Ortam tepki verir → Ödül alır → Strateji güncellenir.

# Pekiştirmeli Öğrenme

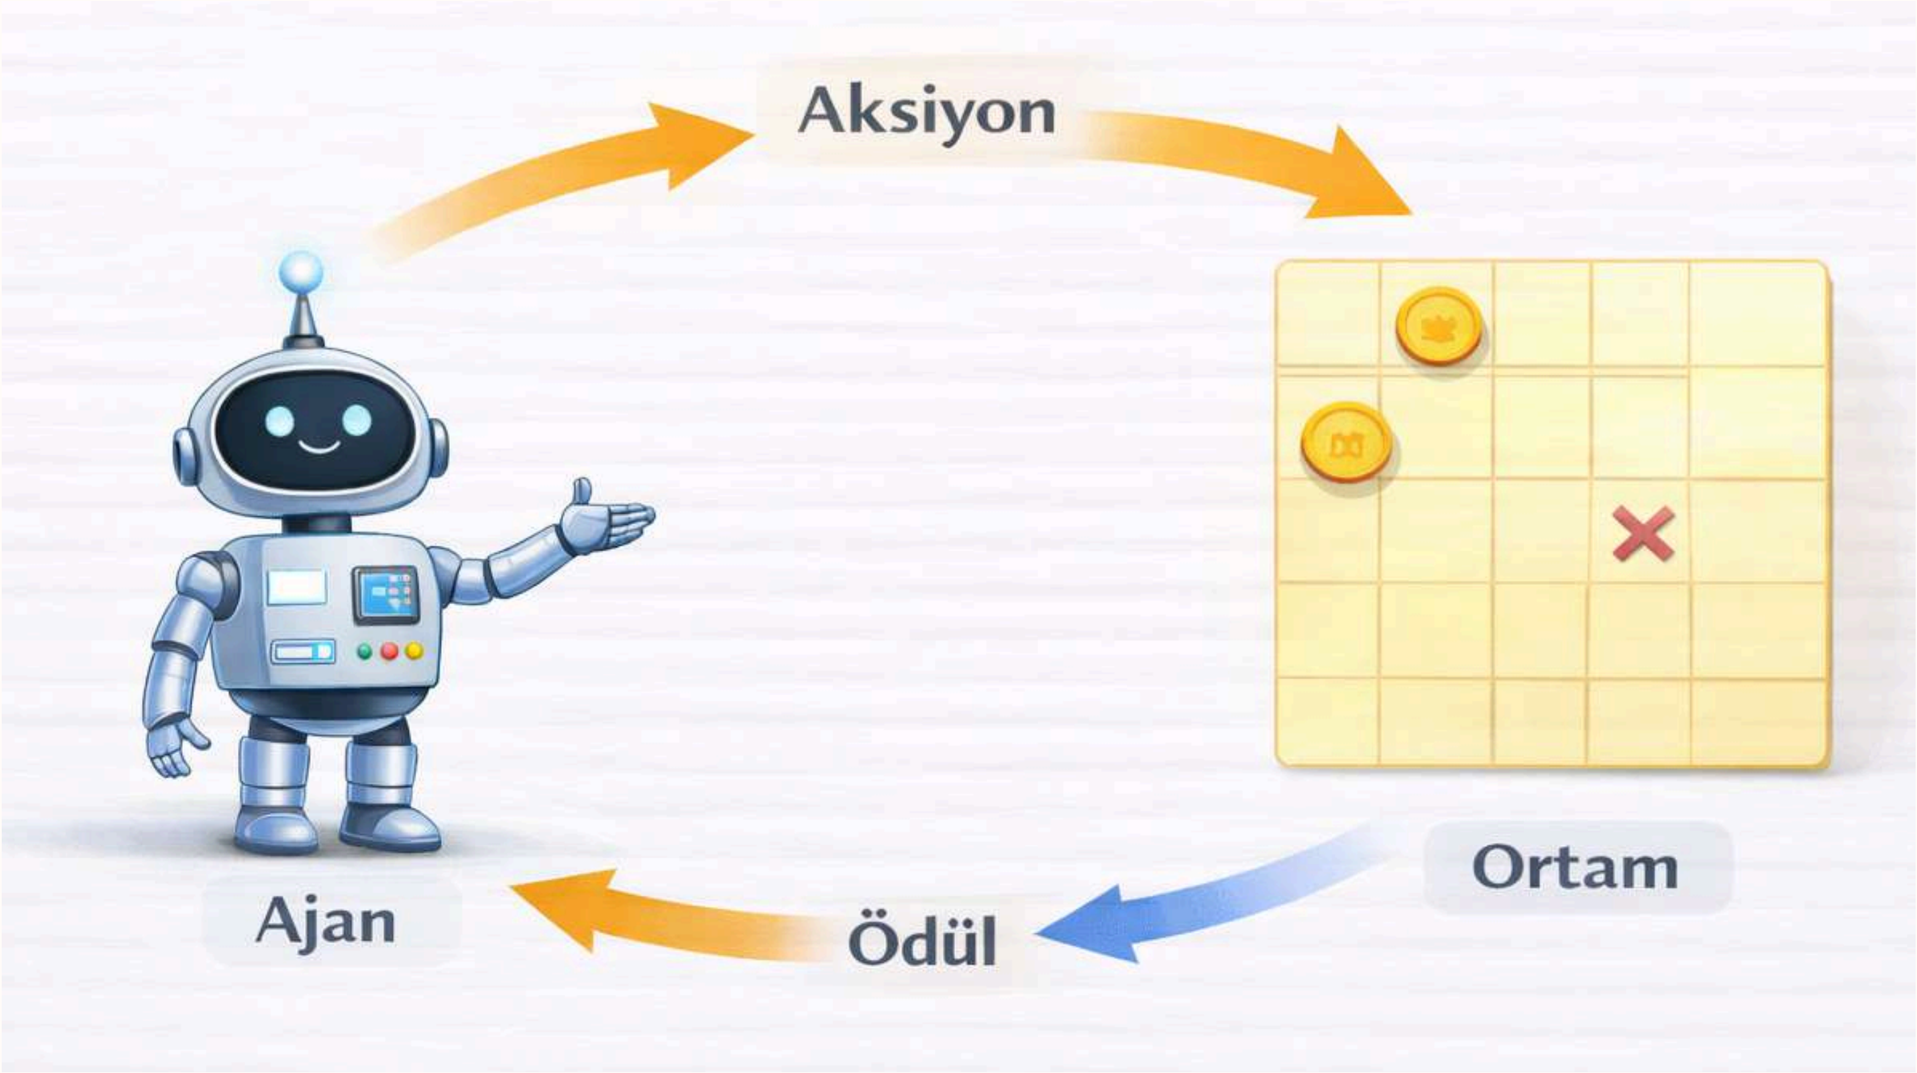

# Temel Algoritmalar

- Makine öğrenmesinde kullanılan temel algoritmalar, verideki ilişkiyi farklı matematiksel yaklaşımlarla modellemeye çalışır. Her algoritma aynı problemi çözebilir; ancak verinin yapısına ve amaca göre performansları değişir.

Örneğin:

- Doğrusal Regresyon: Sayısal bir çıktıyı tahmin etmek için basit bir doğrusal ilişki kurar.
- Karar Ağaçları: Veriyi kurallara bölerek karar mekanizması oluşturur.
- K-En Yakın Komşu (KNN): Benzer örneklere bakarak tahmin yapar.
- Destek Vektör Makineleri (SVM): Verileri en iyi ayıran sınırı bulmaya çalışır.

Temelde hepsinin amacı aynıdır: Veriyi en iyi açıklayan matematiksel yapıyı bulmak.

# Temel Algoritmalar

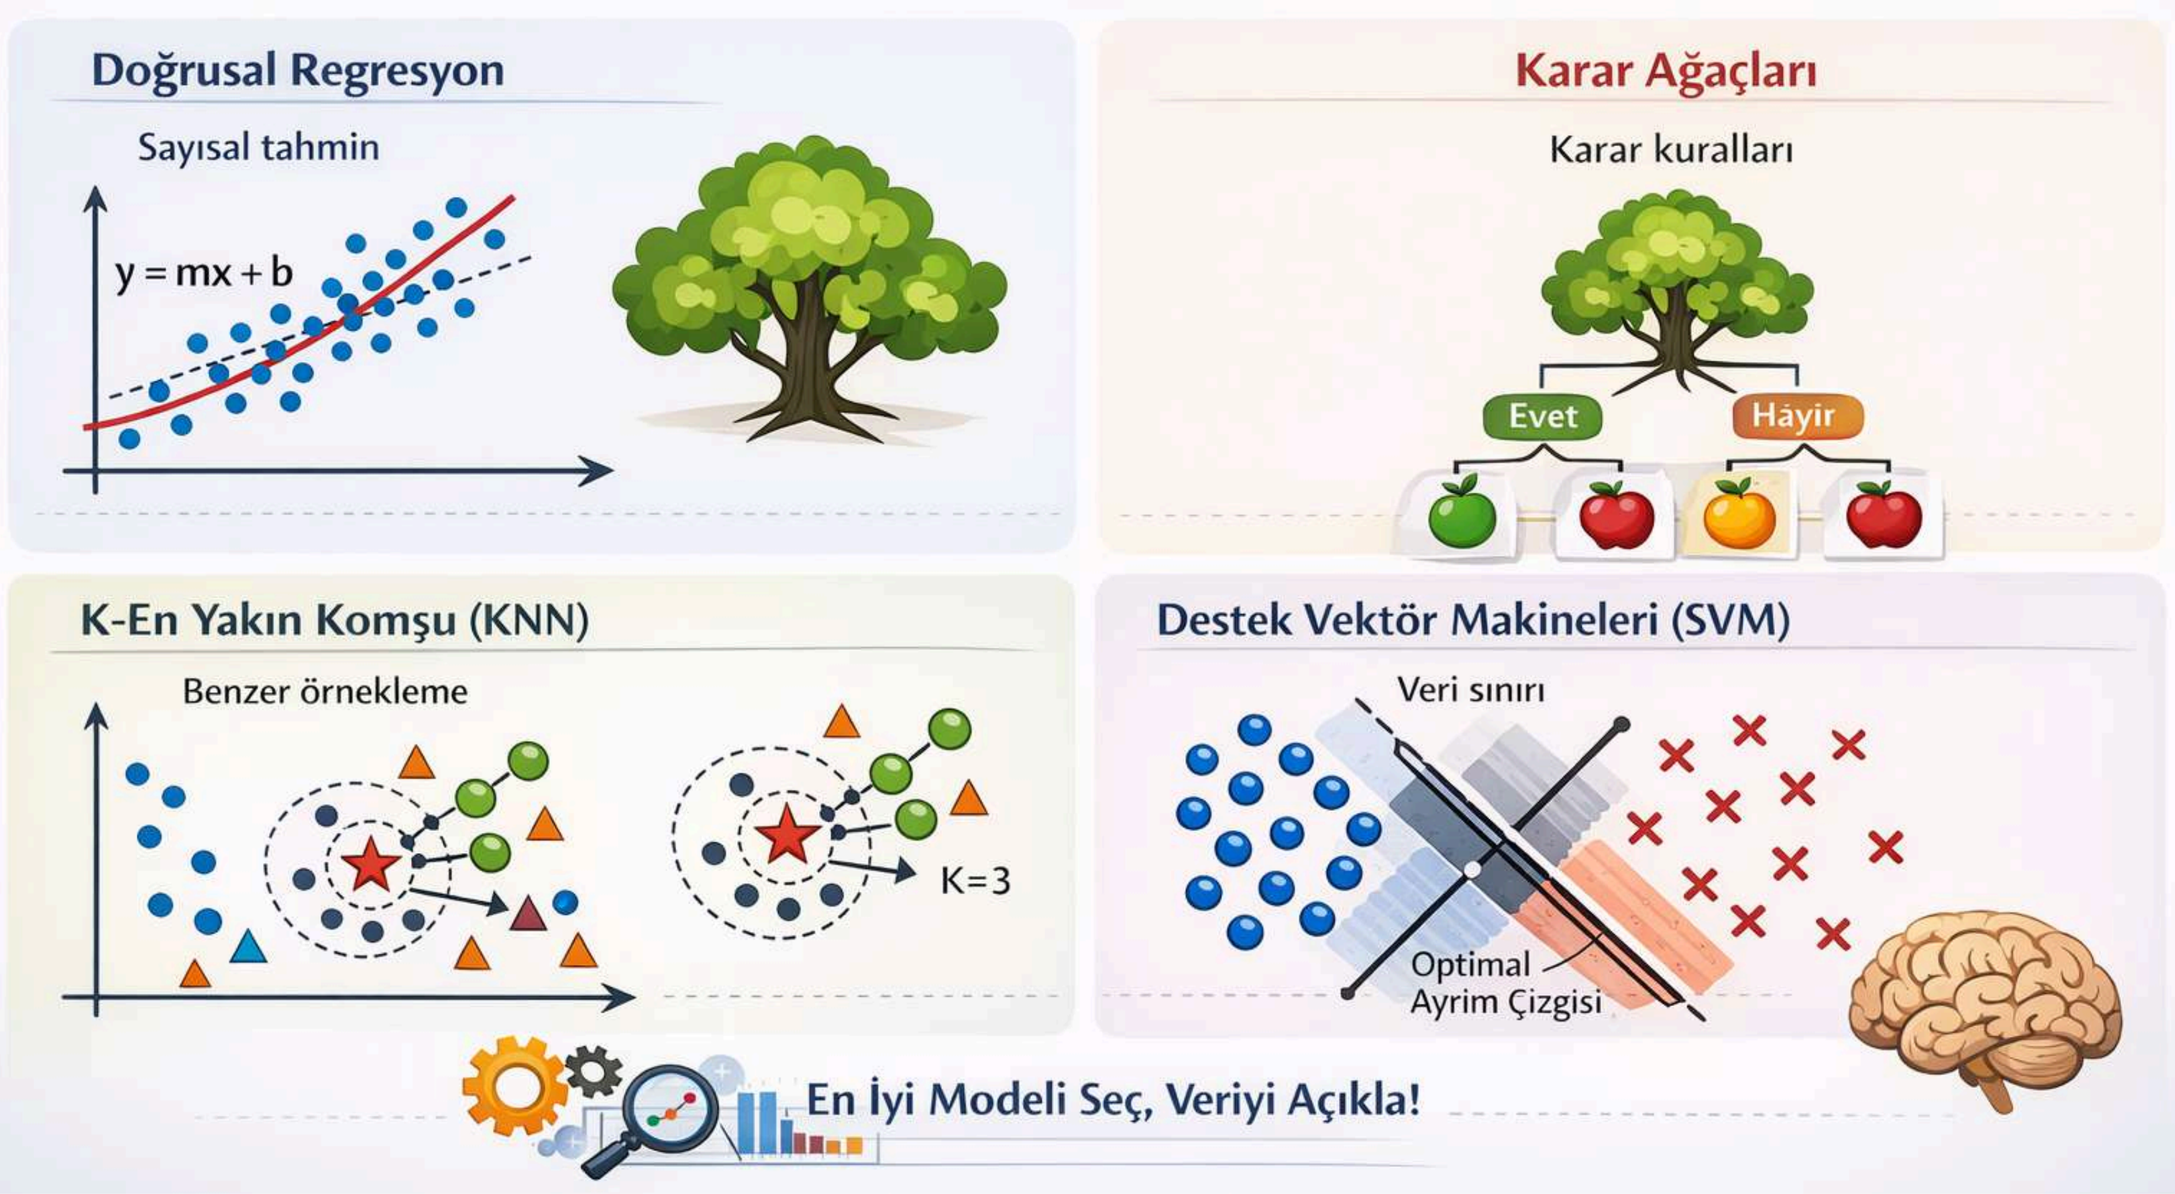

# Sinir Ağları

- Sinir ağları, insan beynindeki nöronlardan ilham alınarak geliştirilmiş matematiksel modellerdir. Birbirine bağlı katmanlardan oluşur ve her katman, veriyi bir miktar daha işleyerek anlamlandırır.

- Basitçe söylemek gerekirse; giriş verisi ağın içine girer, katmanlar boyunca dönüştürülür ve en sonunda bir çıktı üretilir. Bu süreçte ağ, yaptığı hataya göre bağlantı ağırlıklarını güncelleyerek öğrenir.

- Özellikle görüntü, ses ve metin gibi karmaşık verilerde güçlü sonuçlar üretmeleri nedeniyle günümüzde oldukça yaygın kullanılmaktadır.

# Sinir Ağları

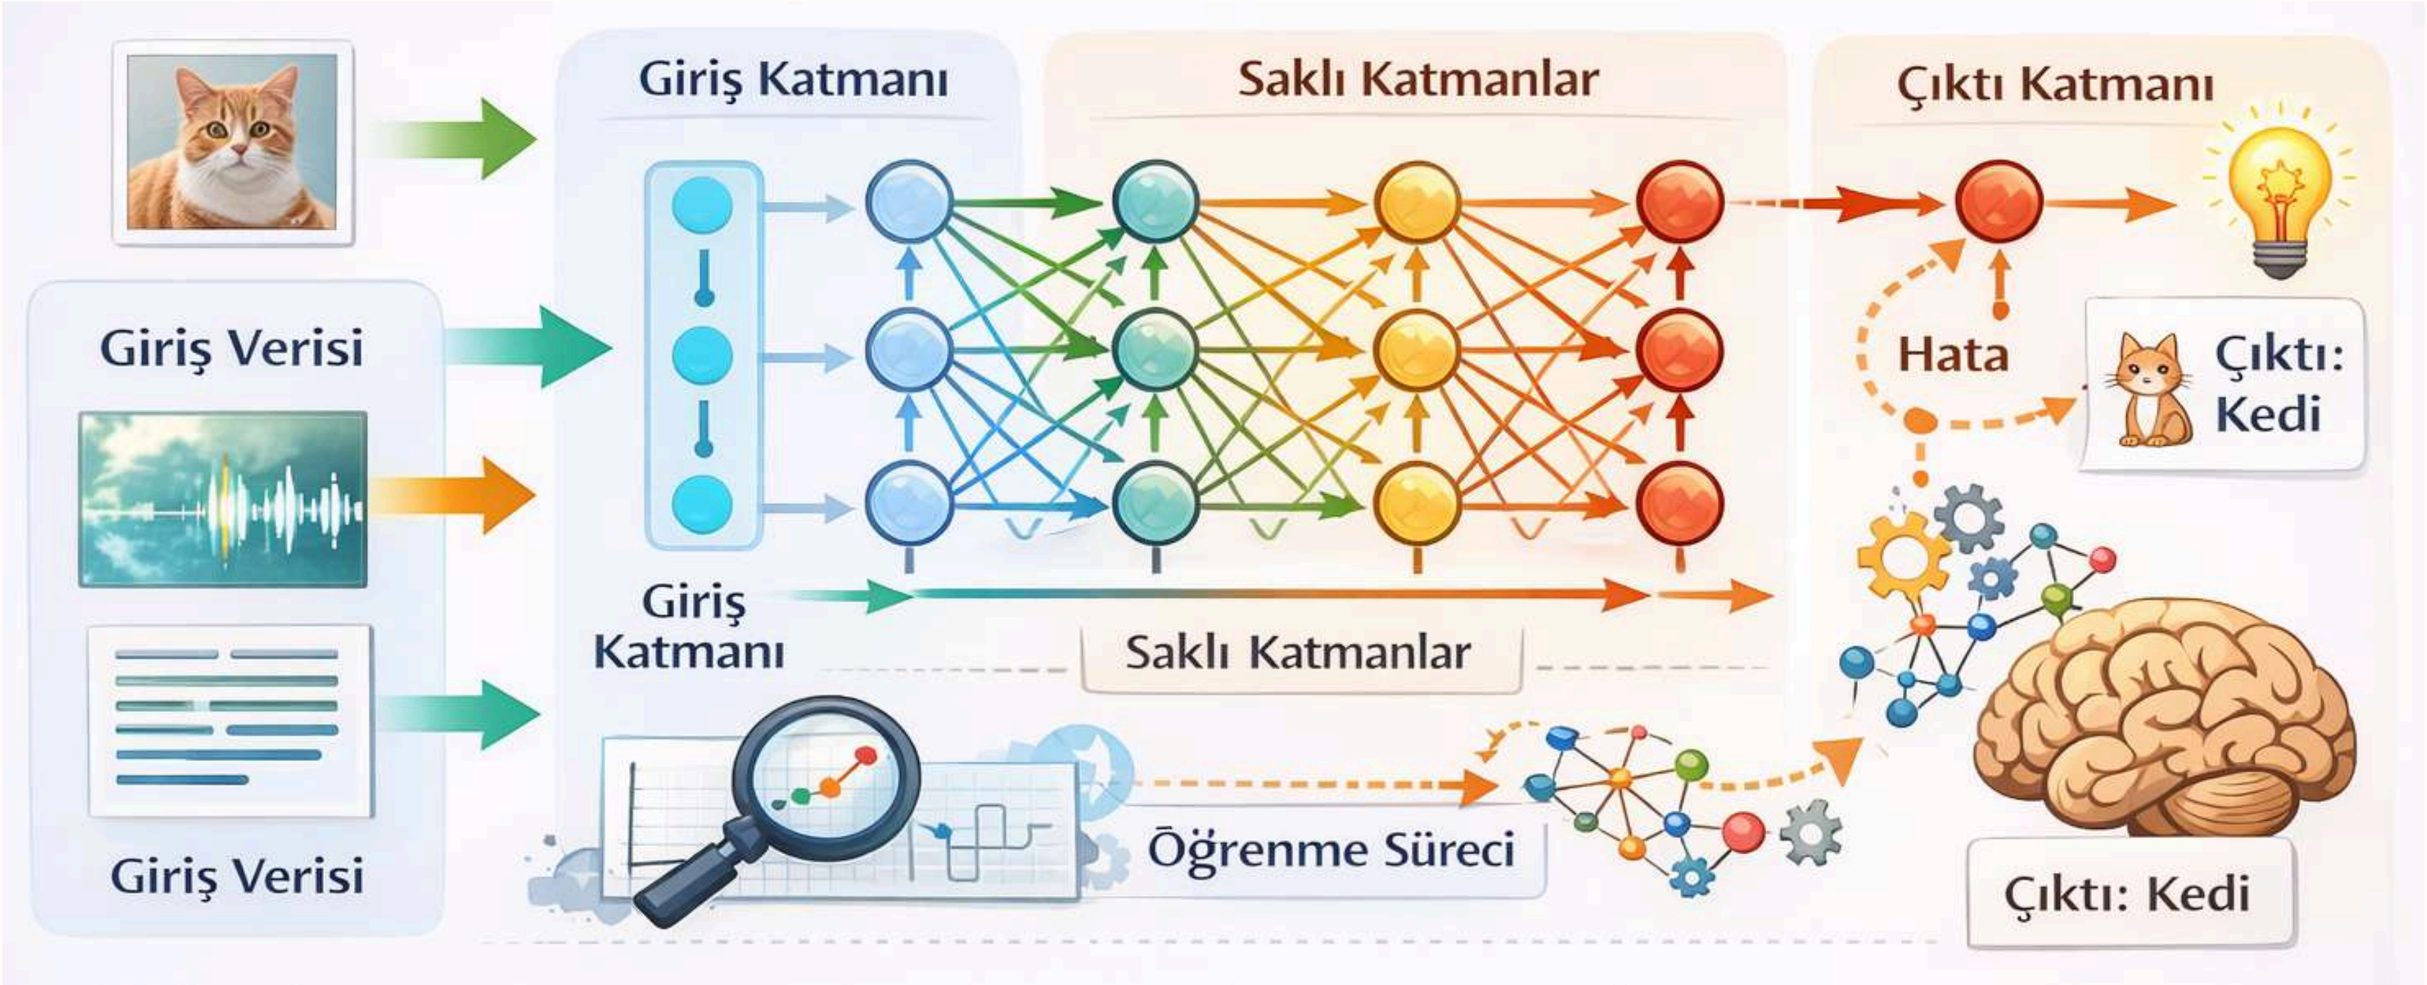

# Derin Öğrenme Neden Güçlü

- Derin öğrenme güçlüdür çünkü verinin içindeki karmaşık ilişkileri çok katmanlı yapılar aracılığıyla öğrenebilir.
- Geleneksel yöntemlerde özellikler çoğu zaman insan tarafından belirlenirken, derin öğrenme bu süreci otomatikleştirir.
- Model, ham veriyi adım adım işleyerek daha soyut ve anlamlı temsiller üretir. Bu nedenle özellikle görüntü, ses ve metin gibi karmaşık veri türlerinde yüksek başarı sağlar.

# Derin Öğrenme Neden Güçlü

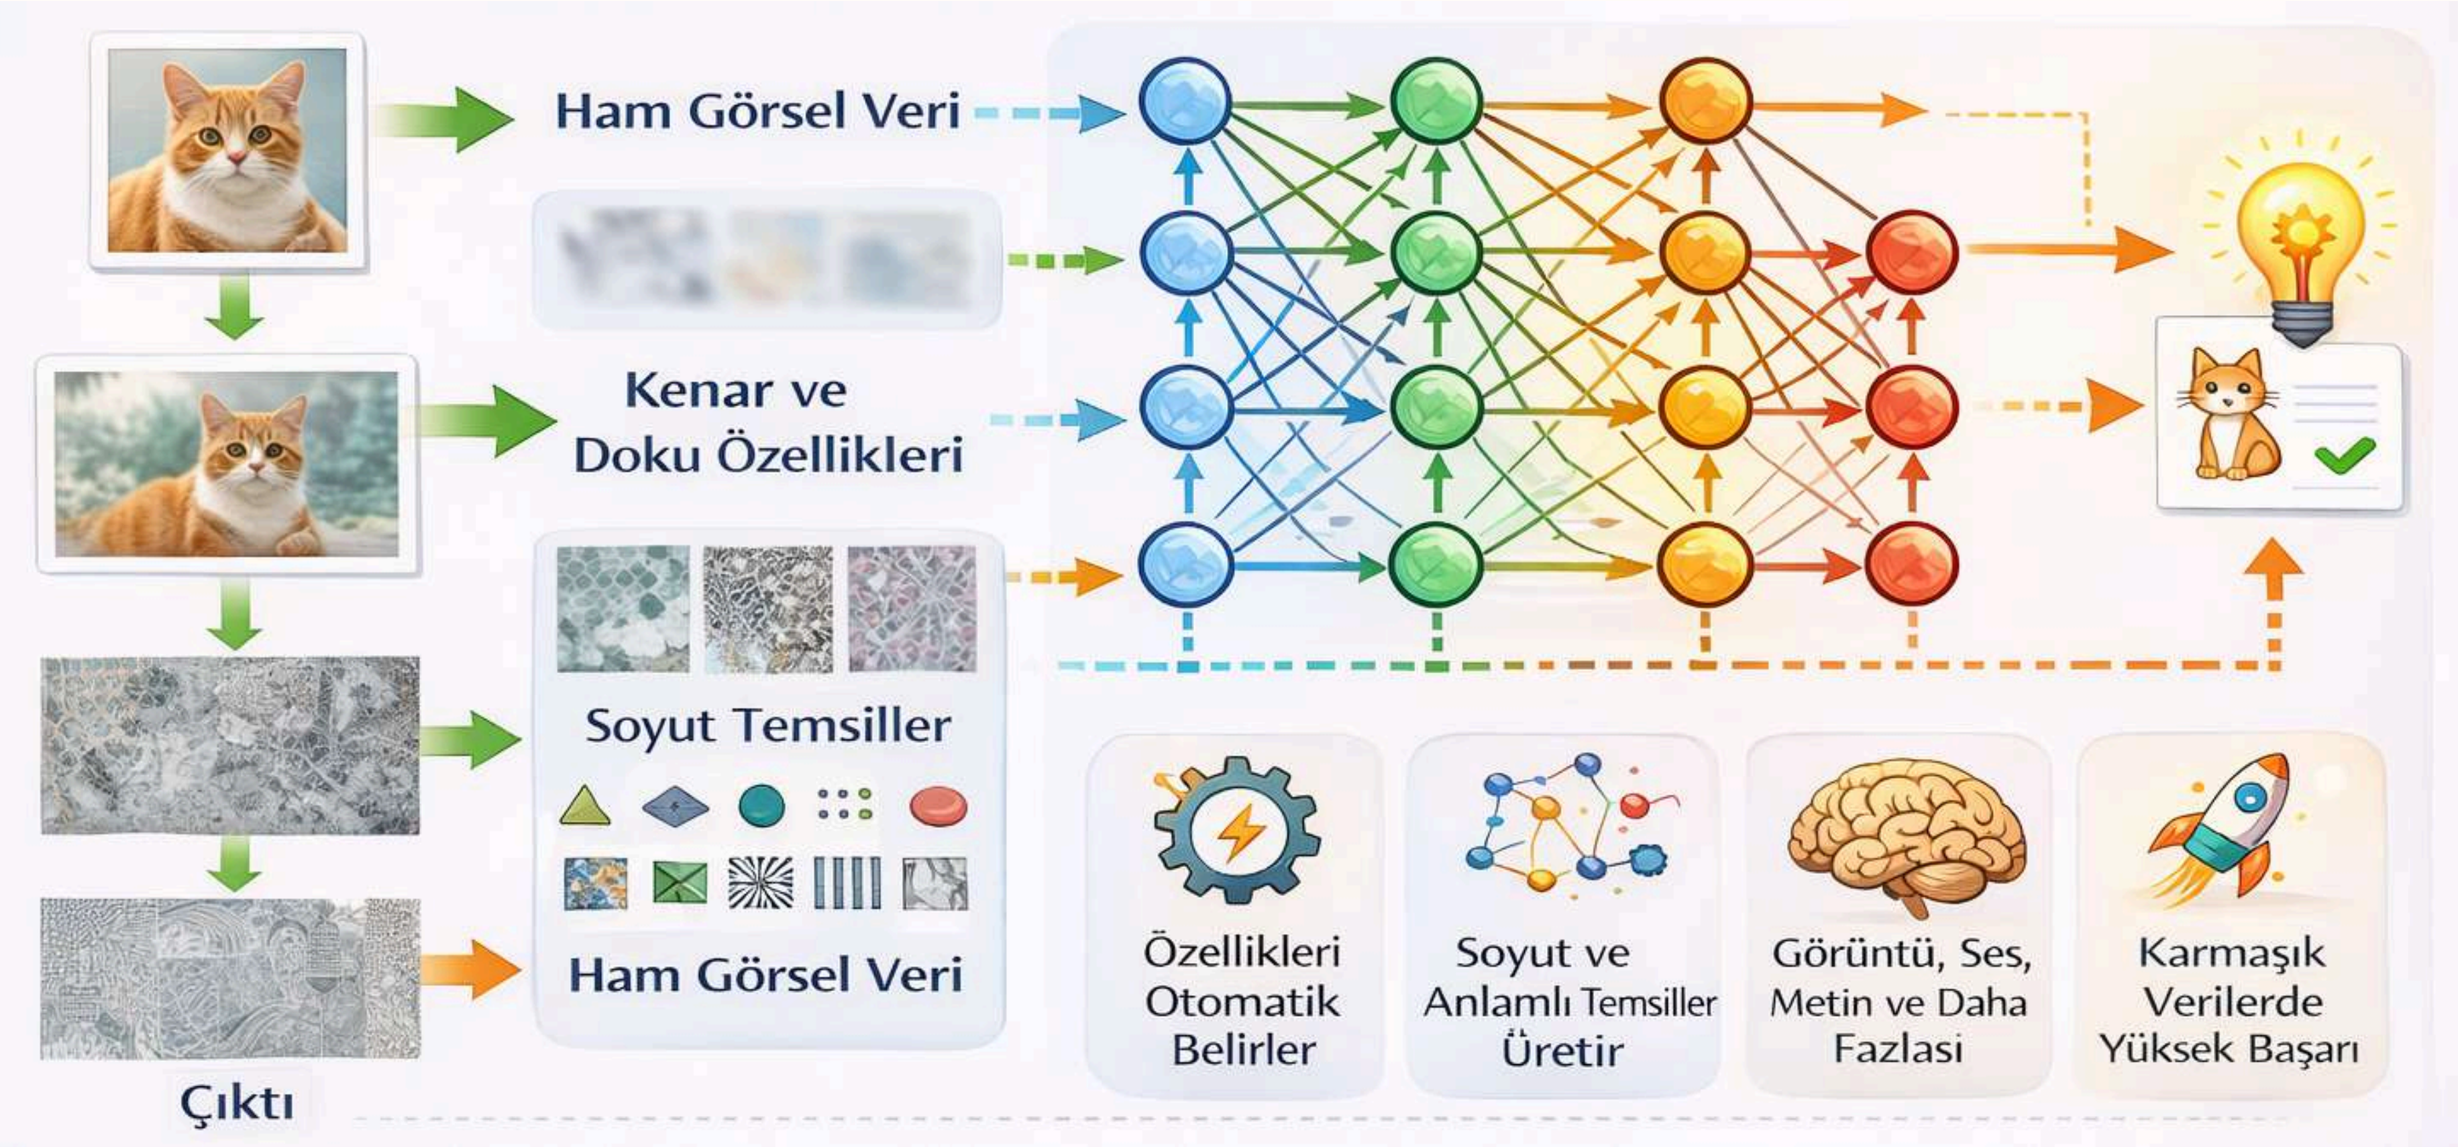

# Eğitim Süreci (Pipeline)

- Makine öğrenmesinde eğitim süreci, ham verinin modele dönüştüğü adımlı bir-akış olarak düşünülebilir.

- Süreç genellikle verinin toplanması ve temizlenmesiyle başlar, ardından uygun özellikler seçilir ve model eğitilir.

- Eğitim sırasında model, tahmin ile gerçek sonuç arasındaki farkı ölçer ve parametrelerini buna göre günceller. Son aşamada ise model, daha önce görmediği veriler üzerinde test edilerek performansı değerlendirilir.

- Kısacası pipeline, veriden başlayıp güvenilir bir modele ulaşana kadar izlenen sistematik yol haritasıdır.

# Eğitim Süreci (Pipeline)

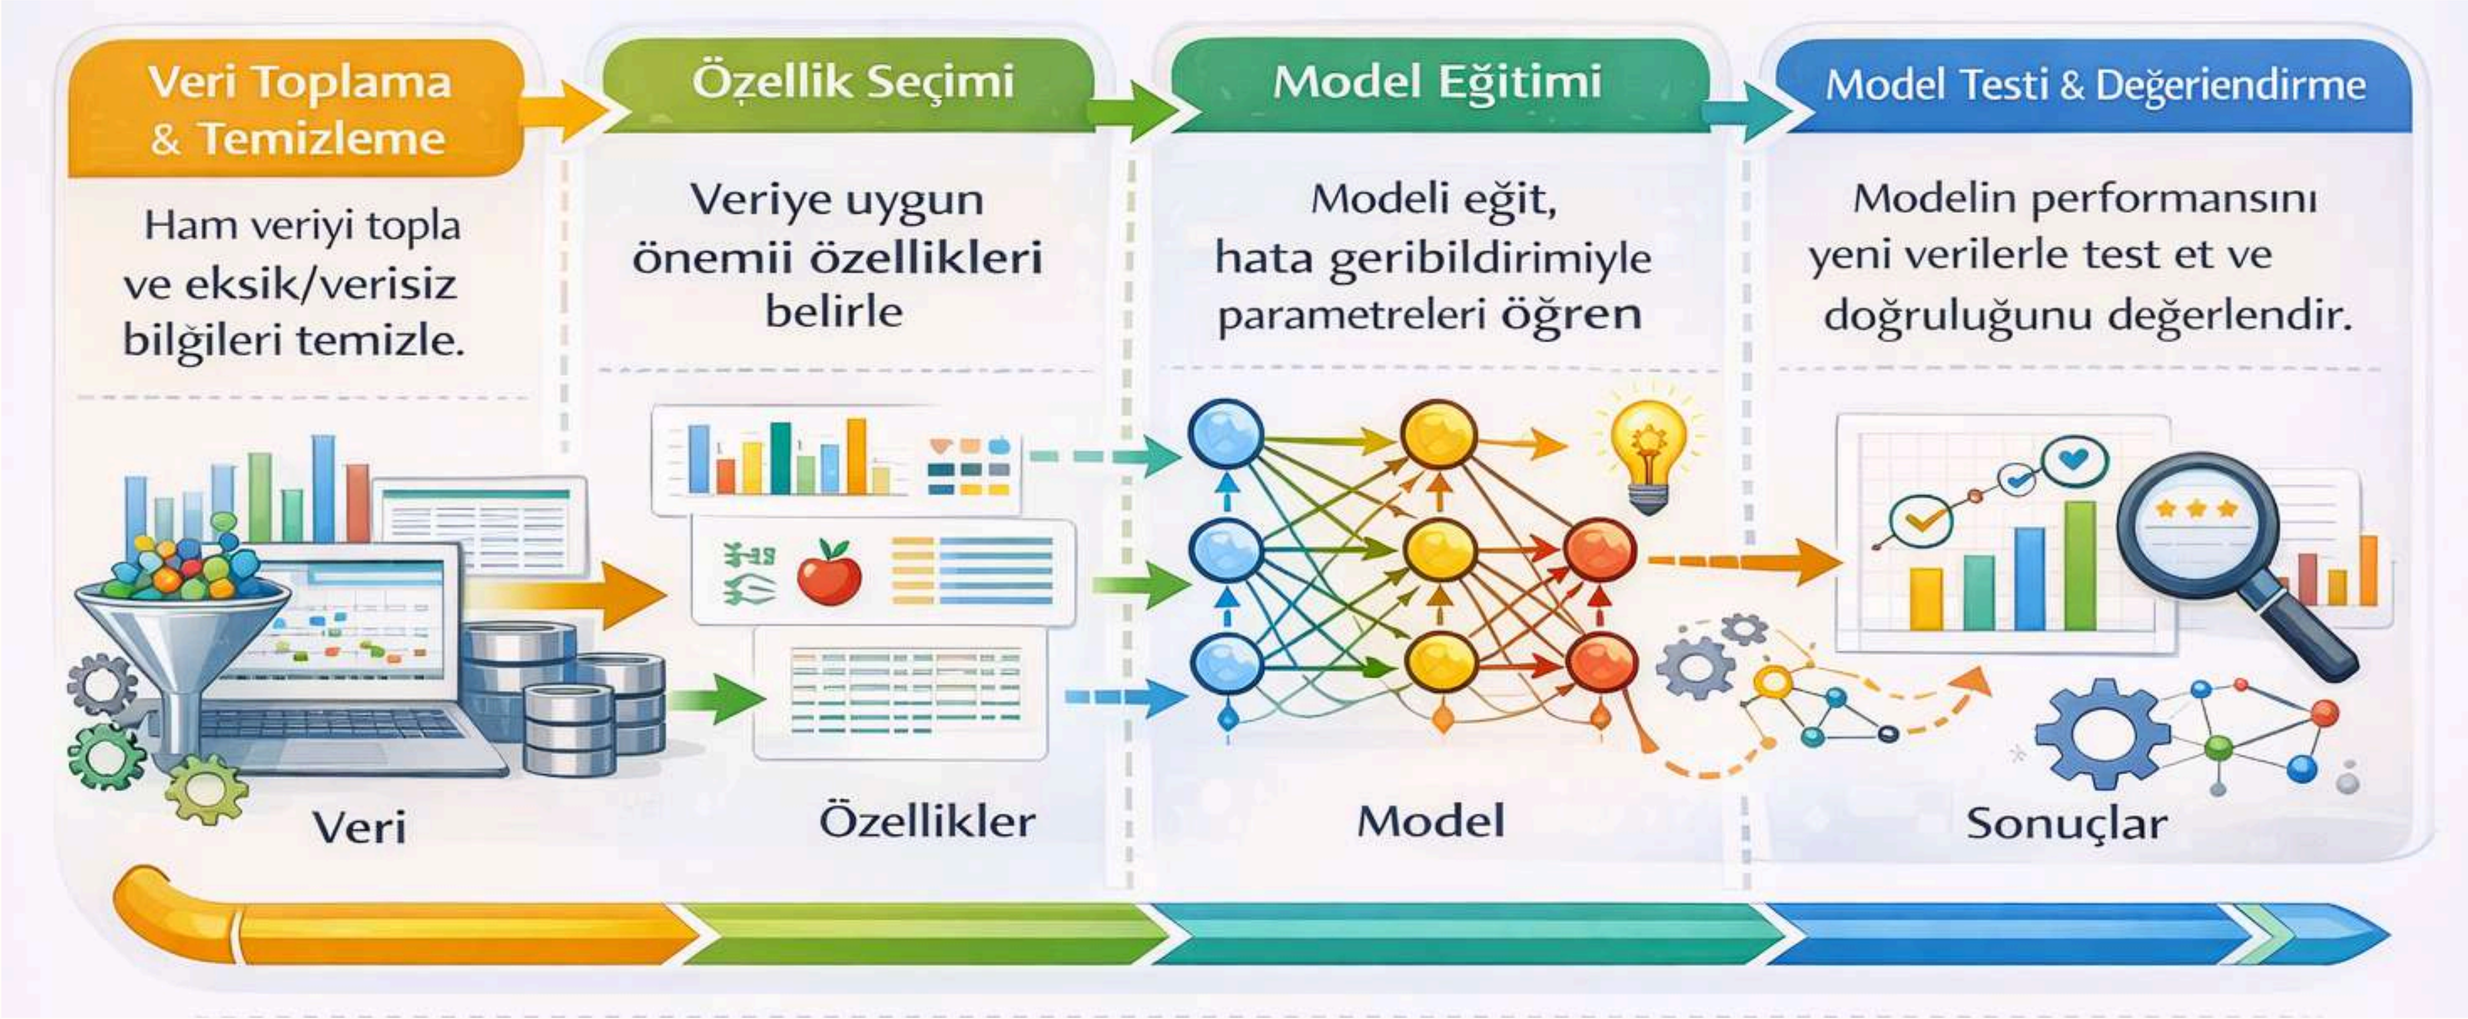

# Veri Kalitesi

- Makine öğrenmesinde model ne kadar iyi olursa olsun, kullanılan veri düşük kaliteliyse sonuçlar da zayıf olur. Bu nedenle veri kalitesi, model başarısının temel belirleyicisidir.

- Eksik, hatalı ya da tutarsız veriler modelin yanlış örüntüler öğrenmesine neden olabilir. Buna karşılık temiz, dengeli ve doğru etiketlenmiş veri, modelin daha güvenilir ve genellenebilir sonuçlar üretmesini sağlar.

- Kısacası, iyi bir modelin arkasında her zaman sağlam bir veri altyapısı vardır.

# Veri Kalitesi

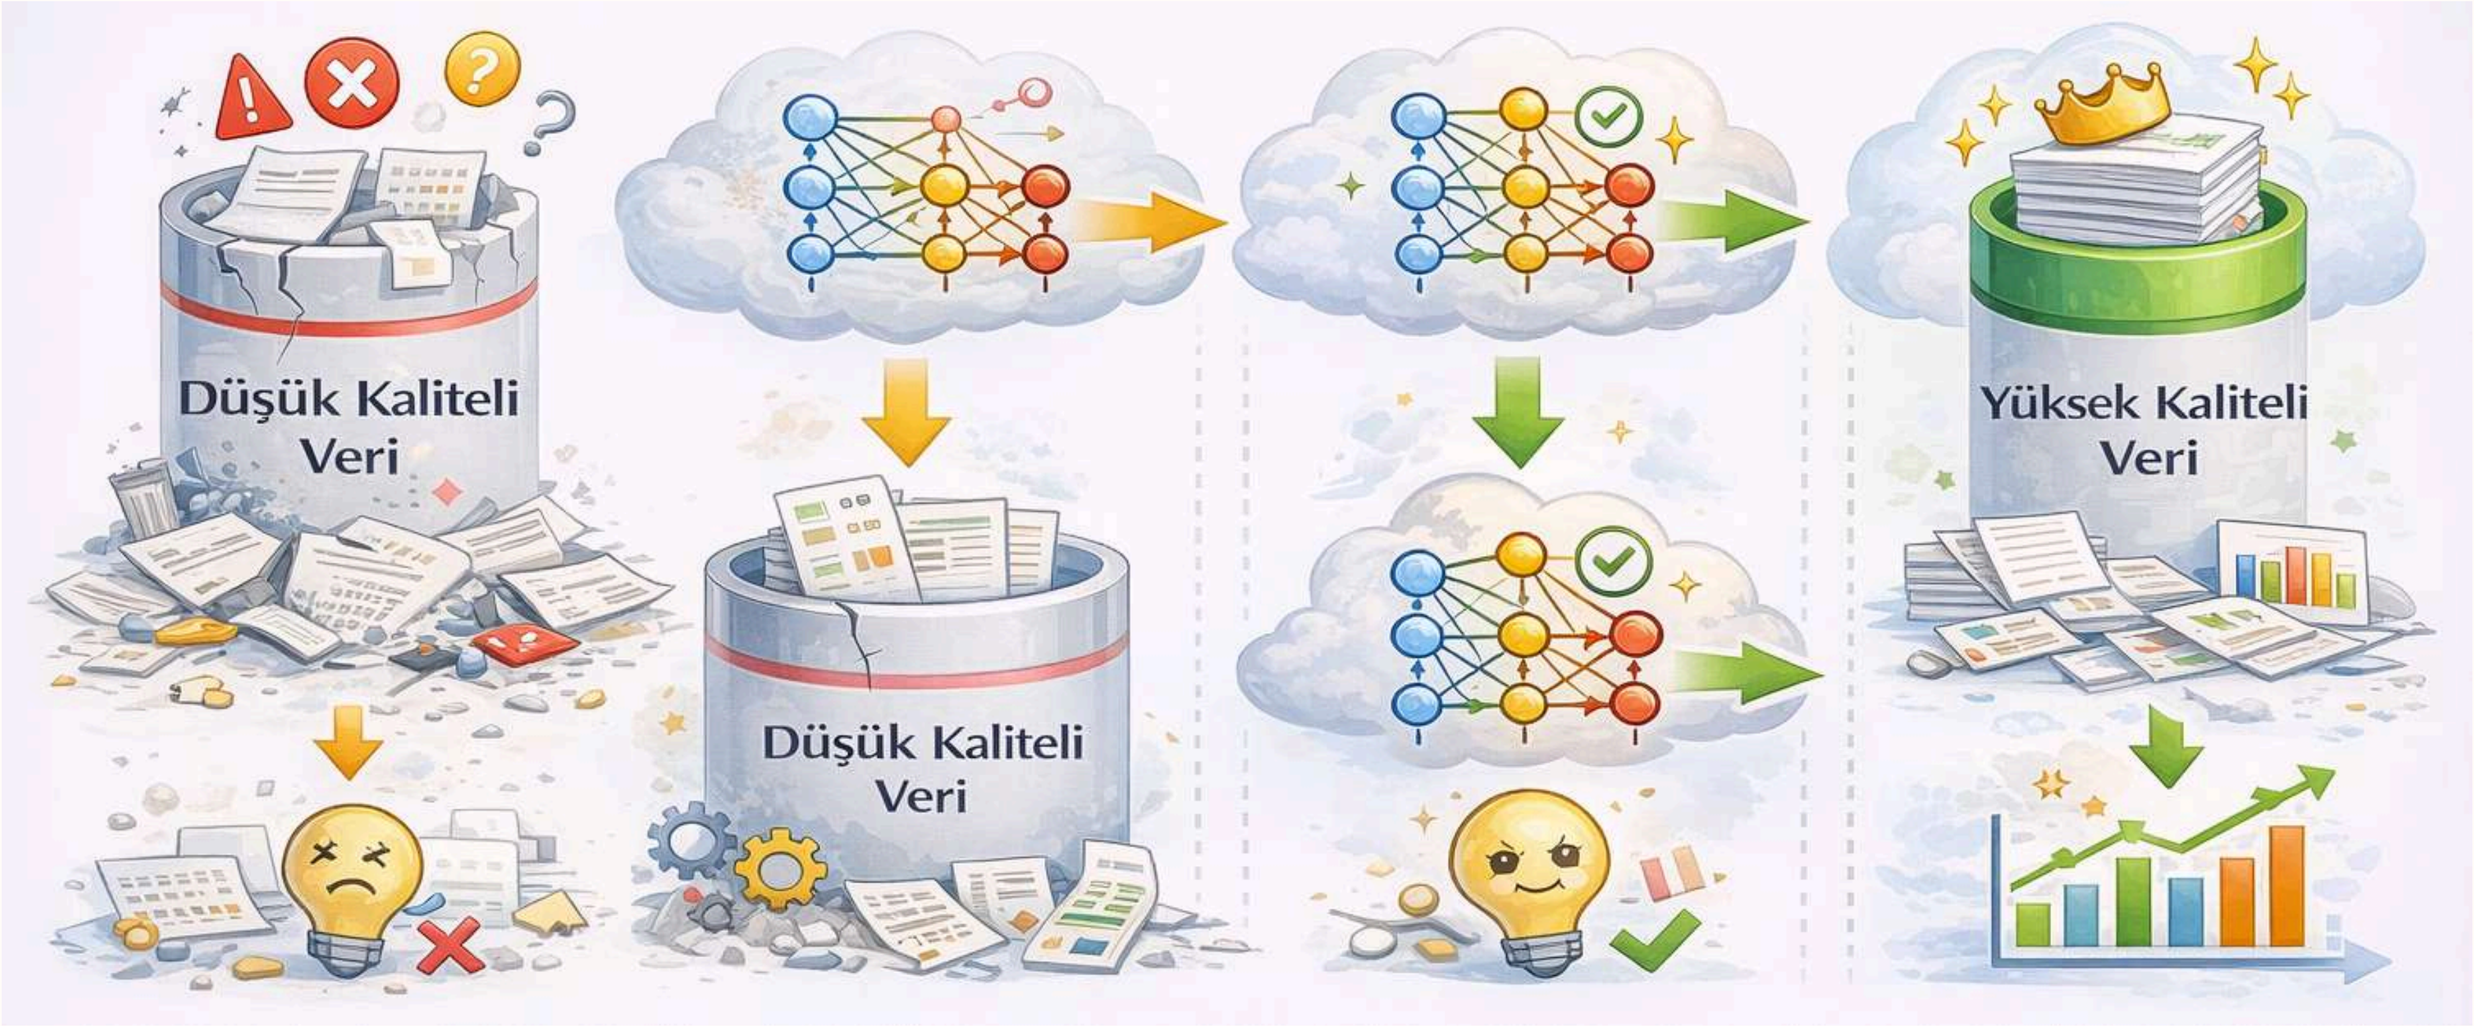

# Eğitim ve Test Ayrımı

- Makine öğrenmesinde verinin tamamı tek seferde modele verilmez. Veri genellikle ikiye ayrılır: eğitim verisi ve test verisi.

- Eğitim verisi, modelin öğrenmesi için kullanılır. Model bu veriler üzerinden parametrelerini ayarlar. Test verisi ise modelin daha önce görmediği örneklerden oluşur ve gerçek performansı ölçmek için kullanılır.

- Bu ayrımın amacı, modelin sadece ezber yapıp yapmadığını değil, yeni veriler üzerinde ne kadar başarılı olduğunu görmek ve genelleme yeteneğini değerlendirmektir.

# Eğitim ve Test Ayrımı

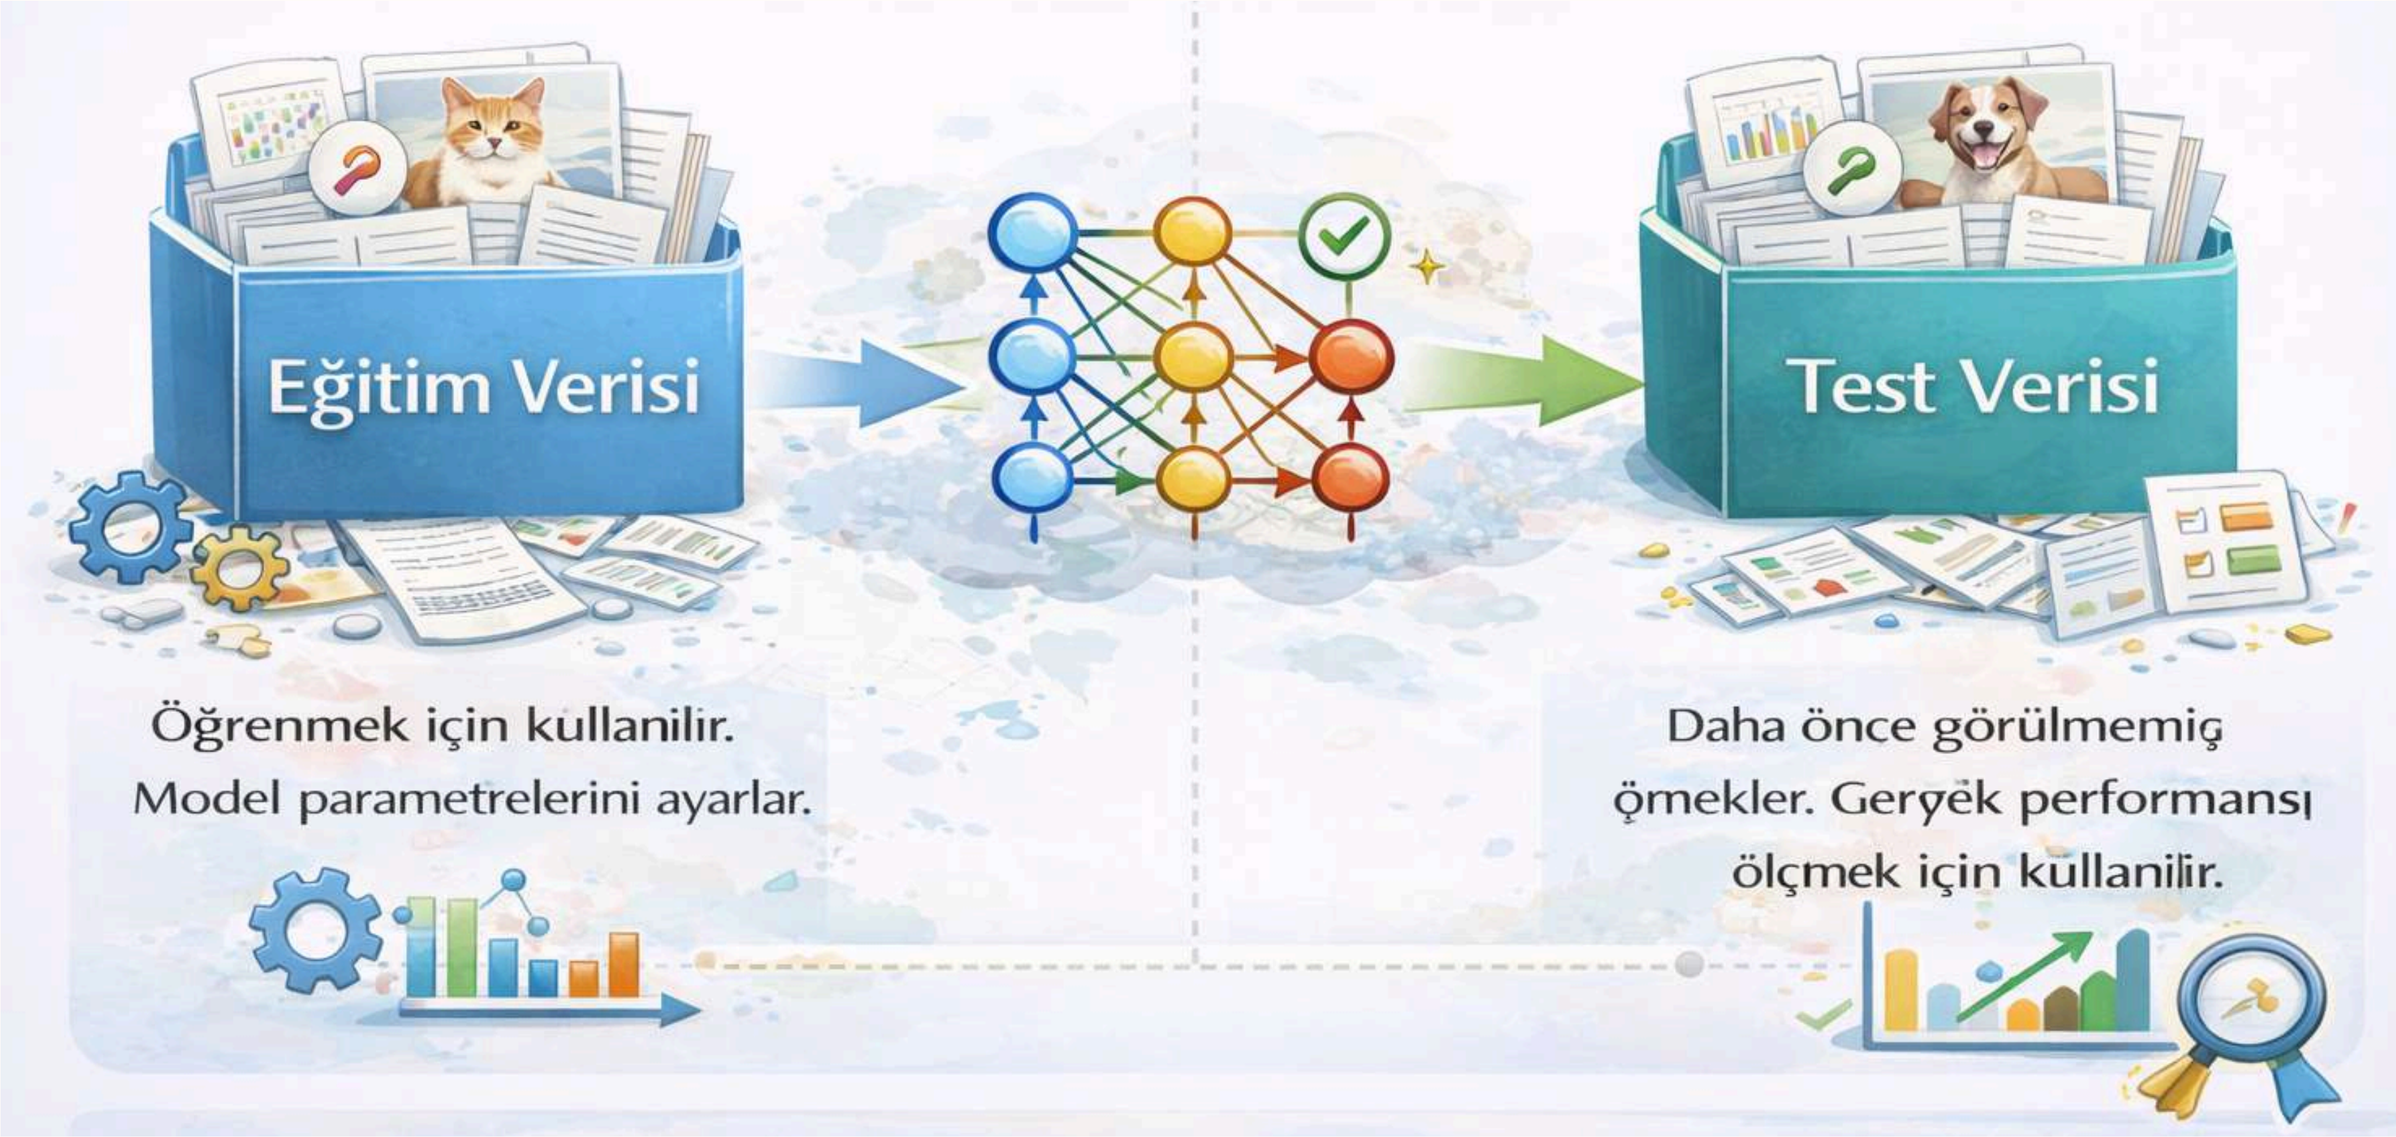

# Overfitting vs Underfitting

- Makine öğrenmesinde modelin veriye uyum seviyesi kritik bir konudur.
- Overfitting (Aşırı Uyum), modelin eğitim verisini gereğinden fazla öğrenmesi durumudur. Model veriyi neredeyse ezberler; eğitimde çok başarılı görünür fakat yeni verilerde performansı düşer.
- Underfitting (Yetersiz Uyum) ise modelin veriyi yeterince öğrenememesidir. Hem eğitim verisinde hem de test verisinde düşük performans gösterir.
- Denge noktası, modelin veriyi ezberlemeden öğrenmesi ve yeni durumlara uyum sağlayabilmesidir.

# Overfitting vs Underfitting

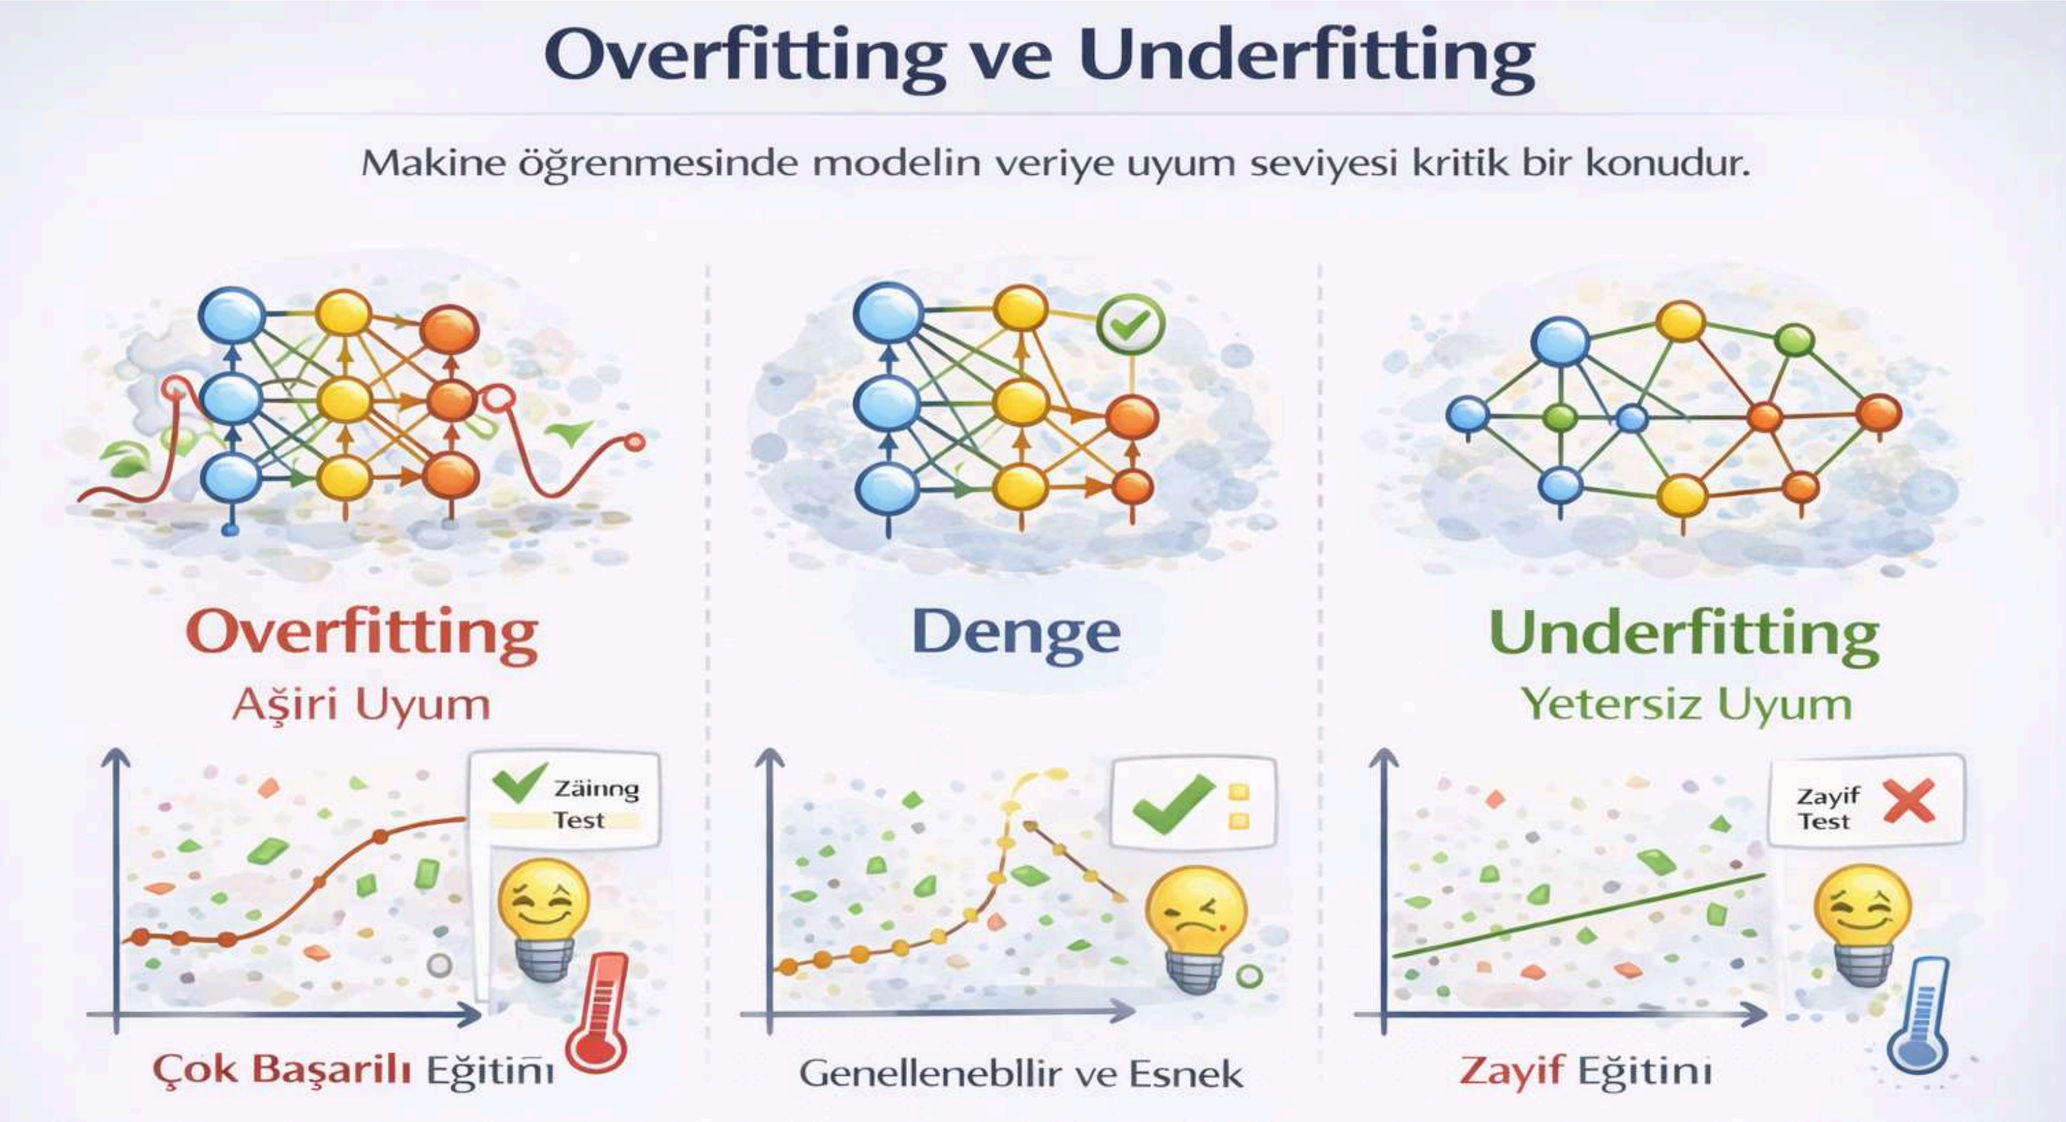

# Genelleme Nedir?

- Genelleme, modelin eğitim sırasında gördüğü verilerden öğrendiklerini daha önce karşılaşmadığı yeni veriler üzerinde de doğru şekilde uygulayabilme yeteneğidir.

- Bir model yalnızca eğitim verisinde iyi sonuç veriyorsa ama yeni verilerde başarısız oluyorsa, gerçek anlamda öğrenmiş sayılmaz. Gerçek öğrenme, bilinmeyen örneklerde de tutarlı performans gösterebilmektir.

- Bu nedenle genelleme, makine öğrenmesinde başarının en önemli göstergelerinden biridir.

# Genelleme Nedir?

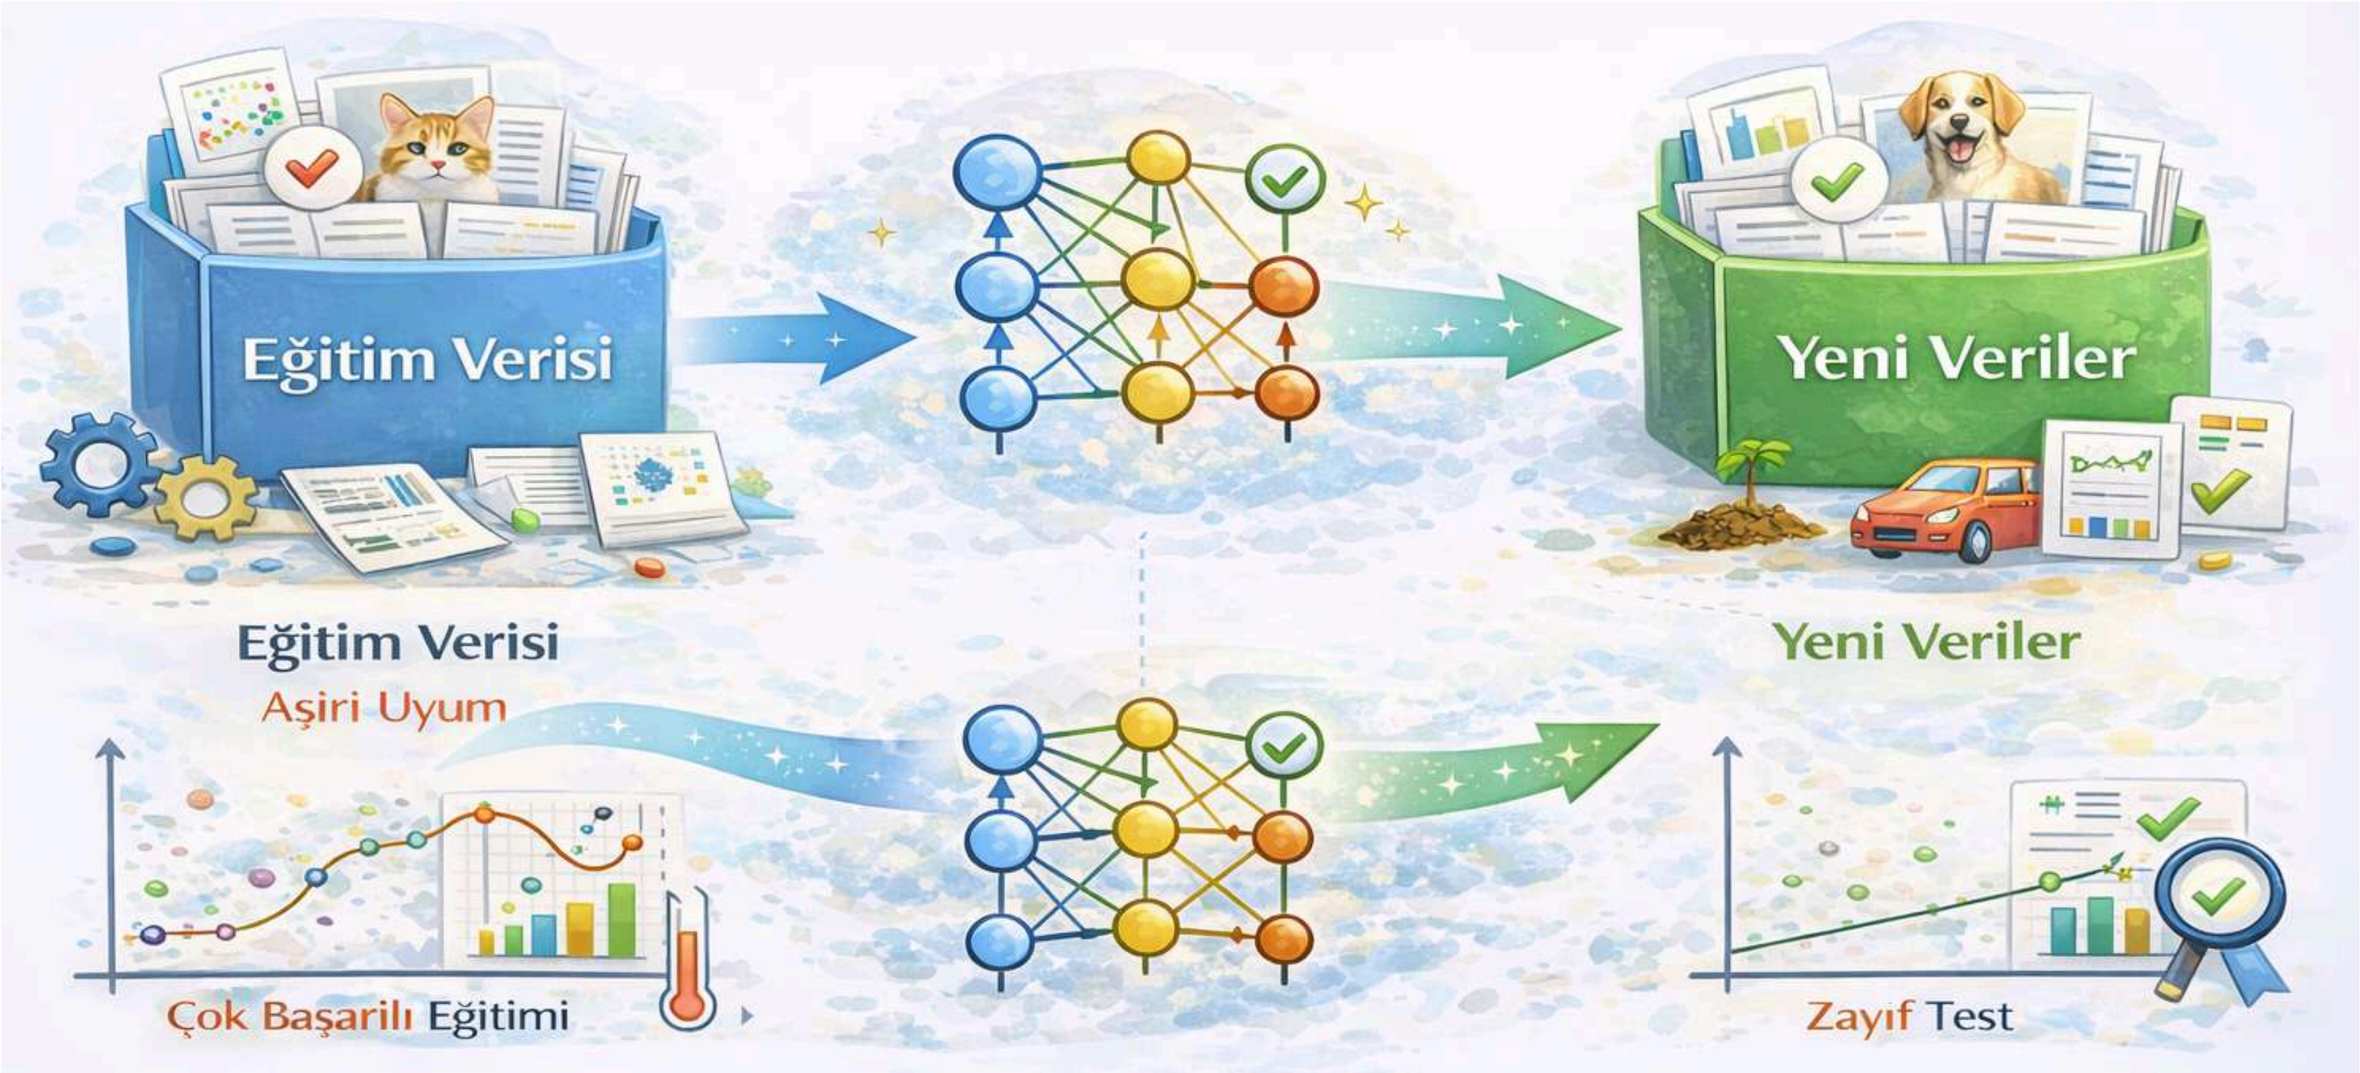

# Bilgi Temsili

- Bilgi temsili, gerçek dünyadaki bilgilerin makine tarafından işlenebilecek bir forma dönüştürülmesidir. Yani soyut kavramlar, ilişkiler ve özellikler matematiksel ya da sembolik yapılarla ifade edilir.

- Bir modelin nasıl düşüneceğini belirleyen şey, bilgiyi nasıl temsil ettiğidir. Çünkü makine veriyi ham hâliyle değil, sayısal ve yapısal bir biçimde “anlar”.

- Kısacası, bilgi temsili doğru kurulmadığında model ne kadar güçlü olursa olsun sağlıklı sonuç üretmek zorlaşır.

# Bilgi Temsili

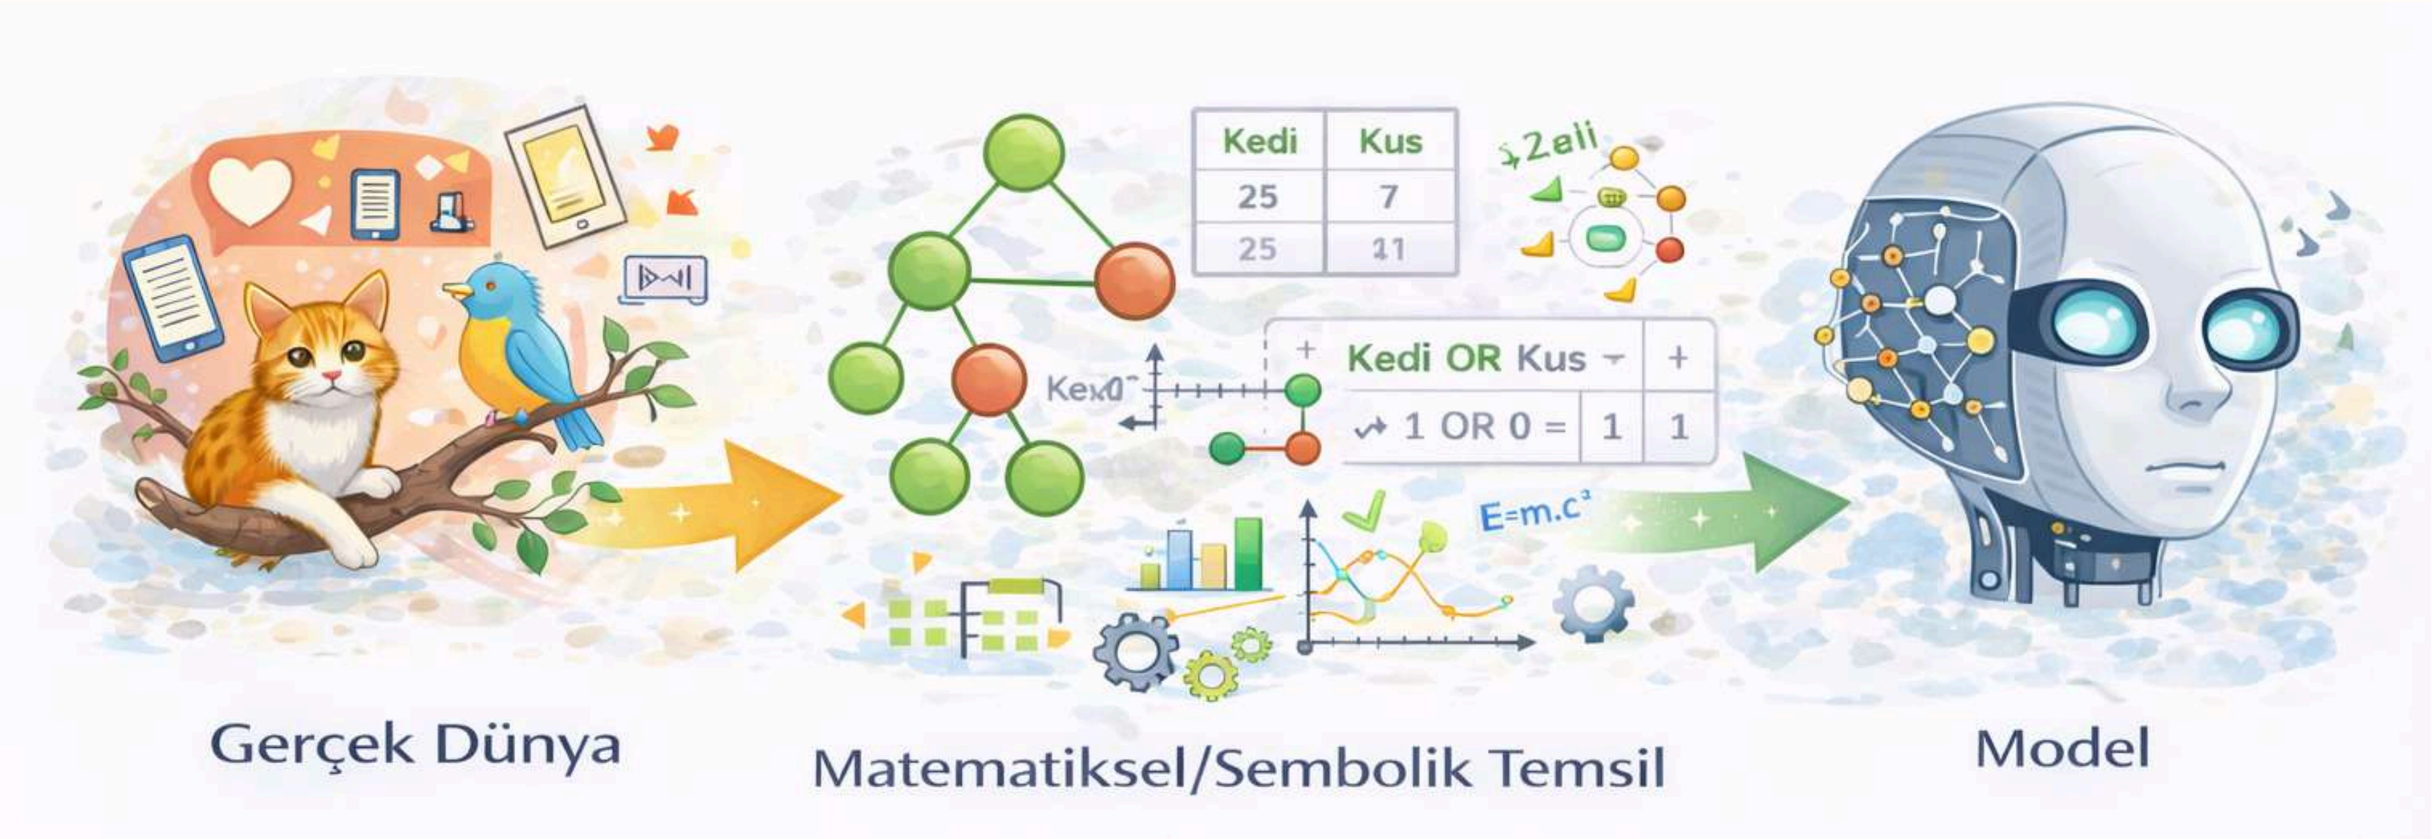

# Model Nasıl “Anlar”?

- Bir model aslında insan gibi “anlamaz”; o, verideki örüntüleri matematiksel ilişkiler olarak öğrenir. Eğitim sürecinde tekrar eden yapıları fark eder ve bu yapıları parametreleri aracılığıyla temsil eder.

- Yani model için anlam, sayısal ilişkilerden ibarettir. Doğru tahmin yapabildiği sürece “anlamış” kabul edilir. Bu nedenle modelin anlama süreci, sezgisel değil istatistiksel bir uyum sürecidir.

# Model Nasıl “Anlar”?

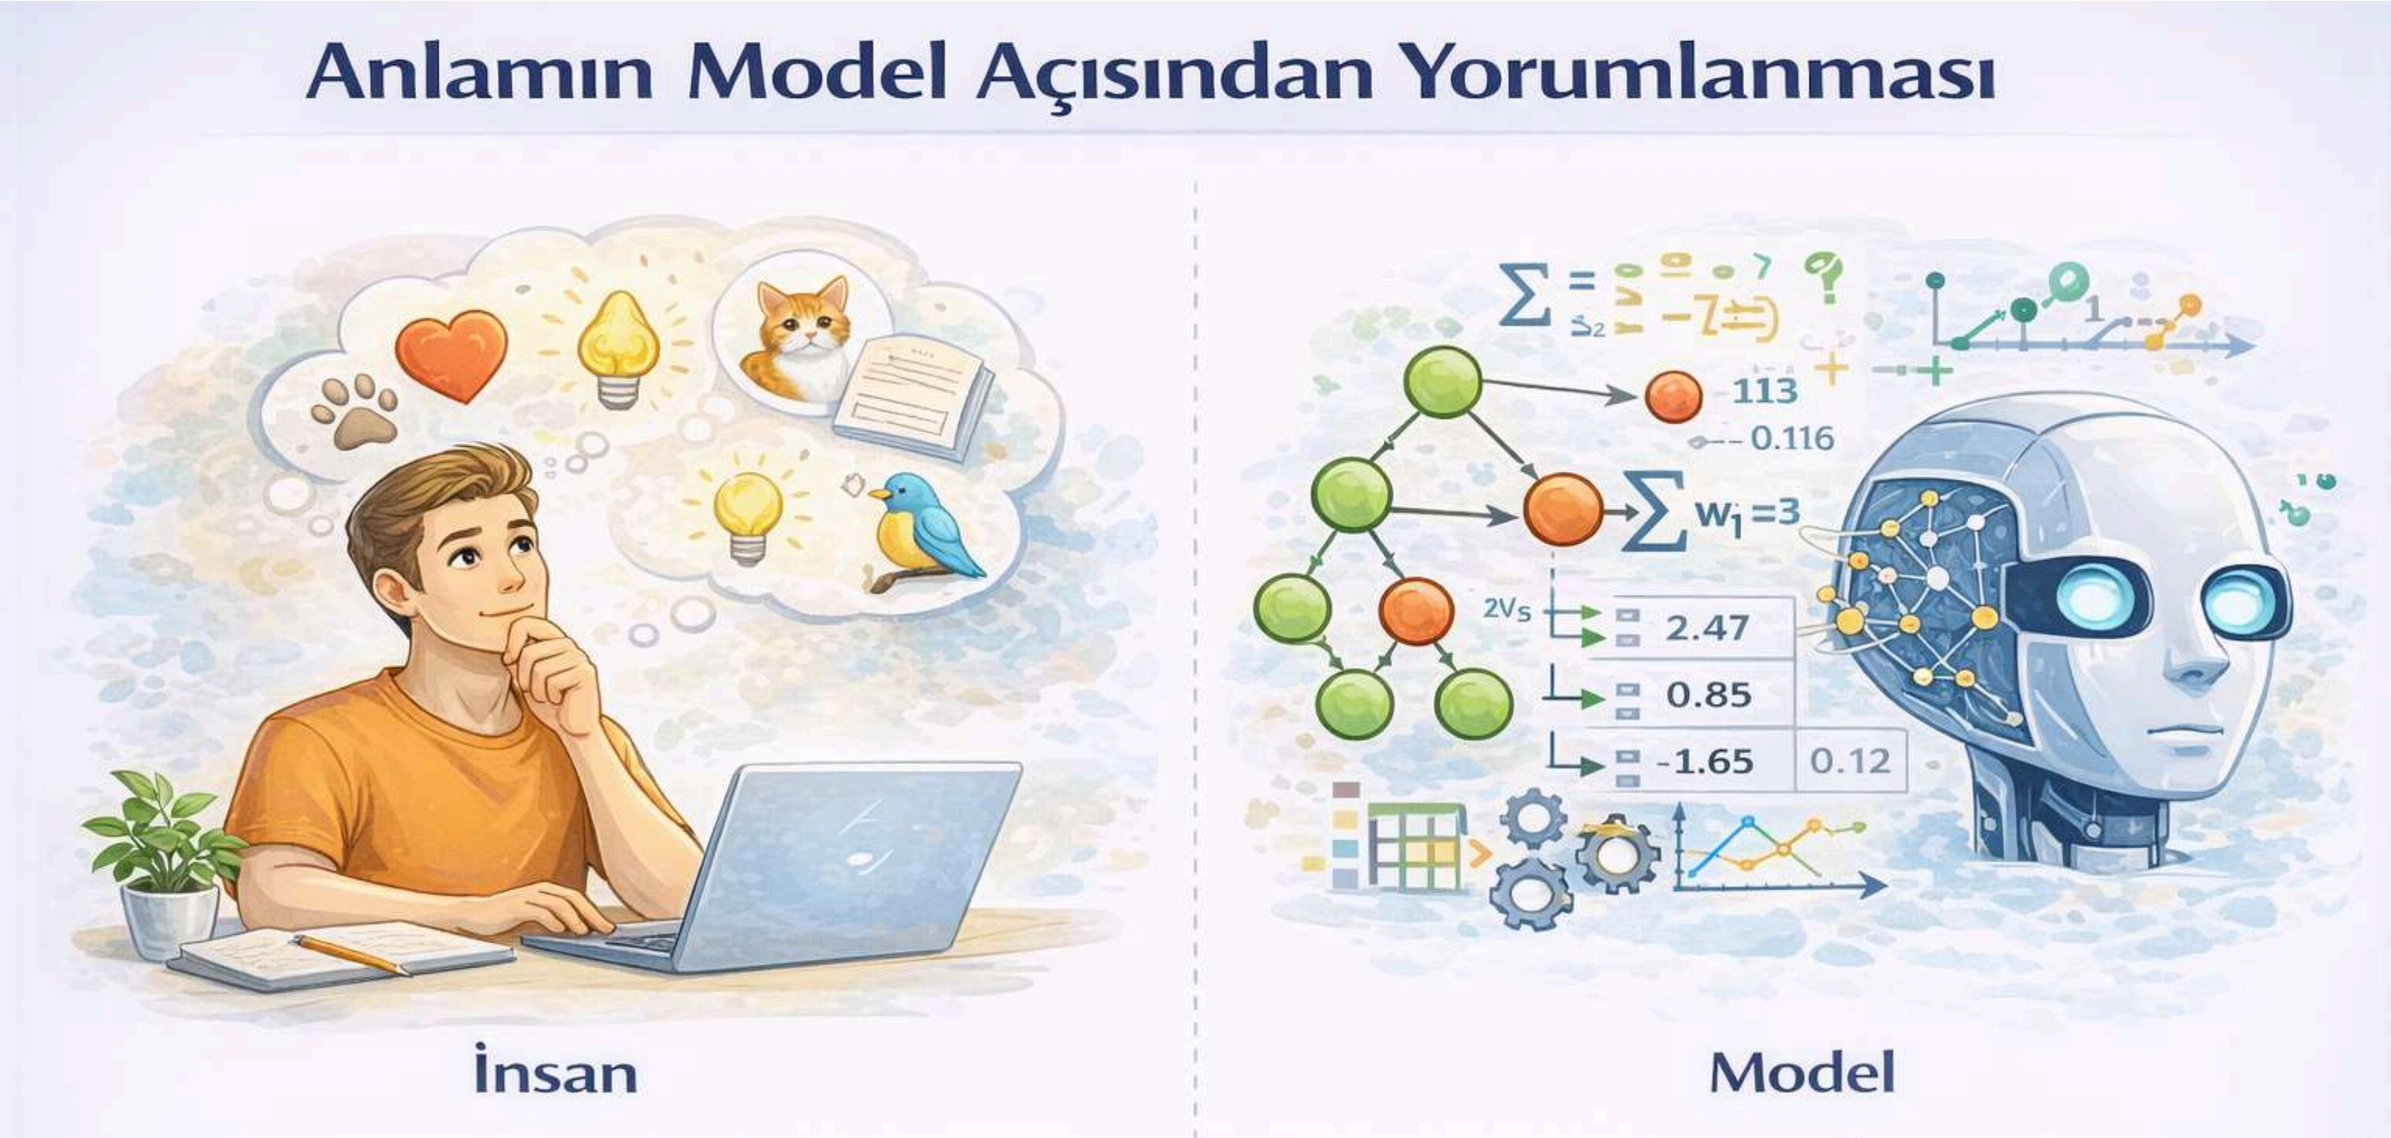

# Güncel Araştırma Alanları

- Yapay zekâ alanında araştırmalar yalnızca daha doğru tahmin yapan modeller geliştirmekle sınırlı değil. Günümüzde açıklanabilir yapay zekâ (XAI), etik ve güvenilir AI sistemleri, büyük dil modelleri ve otonom sistemler gibi konular öne çıkıyor.

- Ayrıca daha az veriyle öğrenebilen, enerji verimliliği yüksek ve gerçek zamanlı karar verebilen modeller geliştirmek de önemli bir araştırma odağı hâline gelmiş durumda.

- Kısacası, güncel çalışmalar yalnızca “daha güçlü” değil, aynı zamanda daha güvenilir ve sürdürülebilir yapay zekâ sistemleri üretmeye odaklanıyor.

# Güncel Araştırma Alanları

# Veri ve Etik

- Yapay zekâ sistemleri veriye dayanır; ancak her veri teknik olduğu kadar etik bir sorumluluk da taşır. Kişisel bilgilerin korunması, verinin adil ve tarafsız olması ve ayrımcılığa yol açmaması büyük önem taşır.

- Eğer veri önyargılıysa, model de bu önyargıyı öğrenir ve kararlarına yansıtır. Bu nedenle yalnızca doğru çalışan değil, aynı zamanda adil ve güvenilir sistemler geliştirmek gerekir.

- Kısacası, veri yalnızca teknik bir kaynak değil; etik bir sorumluluktur.

# Kritik Tartışma

**Makine gerçekten öğreniyor mu, yoksa yalnızca istatistiksel tahmin mi yapıyor?**

- Makine öğrenmesinde “öğrenme” kavramı, insan öğrenmesinden farklıdır. Model, bilinçli bir anlayış geliştirmez; **verideki istatistiksel ilişkileri yakalar ve bu ilişkiler üzerinden tahmin üretir.**

Bu nedenle bazı araştırmacılar, makinelerin gerçekten öğrenmediğini, yalnızca olasılıksal desenleri hesapladığını savunur.

Diğer bir görüş ise, eğer sistem deneyimle performansını artırıyorsa bunun teknik anlamda öğrenme olduğunu kabul eder.

**Sonuç olarak mesele, “öğrenme”yi nasıl tanımladığımıza bağlıdır:**

Bilinçli kavrayış mı, yoksa ölçülebilir performans artışı mı?

# Kritik Tartışma

## Yalnızca İstatistiksel Tahmin

Makineler gerçekten öğrenmez,
yalnizca olasiliksal desenleri hesaplar.

## Teknik Anlamda Öğrenme

Eğer sistem performansını artinyorsa,
bu teknik anlamda öğremnedir.

# Özet

- Yapay zekâ, veriden beslenerek anlamlı çıktılar üretir.
- Öğrenme süreci, hatayı azaltmaya dayalı bir matematiksel optimizasyondur.
- Veri kalitesi, model performansının en belirleyici unsurudur.
- Asıl hedef, yalnızca ezberlemek değil; yeni verilerde de başarılı şekilde genelleyebilmektir.

# KAYNAKÇA

İSTANBUL TİCARET ÜNİVERSİTESİ


- **Tom M. Mitchell (1997). Machine Learning. McGraw-Hill.**

https://www.cs.cmu.edu/~tom/mlbook.html

- **Stuart Russell & Peter Norvig (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson**.

https://aima.cs.berkeley.edu/

- **Ian Goodfellow, Yoshua Bengio & Aaron Courville (2016). Deep Learning. MIT Press.**

https://www.deeplearningbook.org

- **Christopher M. Bishop (2006). Pattern Recognition and Machine Learning. Springer.**

https://link.springer.com/book/10.1007/978-0-387-45528-0

# KAYNAKÇA

İSTANBUL TİCARET ÜNİVERSİTESİ


- **Pedro Domingos (2015). The Master Algorithm. Basic Books.**

https://www.masteralgorithm.com

- **OECD (2019). OECD Principles on Artificial Intelligence.**

https://oecd.ai/en/ai-principles

- **European Commission (2020). Ethics Guidelines for Trustworthy AI.**

https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai